语言模型是无监督的多任务学习器

Language Models are Unsupervised Multitask Learners

Alec Radford [*1] **Jeffrey Wu** [*1] **Rewon Child** [1] **David Luan** [1] **Dario Amodei** [**1] **Ilya Sutskever** [**1]

摘 要 (Abstract)

自然语言处理任务（如问答、机器翻译、阅读理解和文本摘要）通常采用在任务特定数据集上进行监督学习的方法来解决。我们证明，当在名为 WebText 的数百万网页组成的新数据集上进行训练时，语言模型能够在没有任何显式监督的情况下开始学习这些任务。当以文档加问题作为条件时，语言模型生成的答案在 CoQA 数据集上达到了 55 的 F1 分数——在不使用该数据集 127,000+ 个训练样本的情况下，匹配或超过了 4 个基线系统中的 3 个。语言模型的容量（capacity）对于零样本任务迁移（zero-shot task transfer）的成功至关重要，增加模型容量能够使跨任务的性能呈对数线性（log-linear）提升。我们最大的模型 GPT-2 是一个拥有 15 亿（1.5B）参数的 Transformer 模型，它在零样本设置下于 8 个受测语言建模数据集中的 7 个上取得了最先进的（SOTA）结果，但仍然对 WebText 欠拟合。模型生成的样本反映了这些改进，包含了连贯的文本段落。这些发现表明，构建能够从自然出现的演示中学习执行任务的语言处理系统是一条极具前景的道路。

1. 引言 (Introduction)

通过结合大规模数据集、高容量模型和监督学习，机器学习系统如今在它们受训的任务上（在期望意义下）表现出色 (Krizhevsky et al., 2012) (Sutskever et al., 2014) (Amodei et al., 2016)。然而，这些系统非常脆弱，对数据分布 (Recht et al., 2018) 和任务规范 (Kirkpatrick et al., 2017) 的微小变化十分敏感。当前的系统更适合被描述为“狭隘的专家（narrow experts）”，而非“称职的通才（competent generalists）”。我们希望向更加通用的系统迈进——它们能够执行许多任务，并最终无需为每个任务手动创建和标注训练数据集。

[*,**] 同等贡献（Equal contribution） [1]OpenAI，美国加利福尼亚州旧金山。通讯作者：Alec Radford <alec@openai.com>。

构建机器学习系统的主流方法是：收集一个展示目标任务正确行为的训练样本数据集，训练一个系统去模仿这些行为，然后在独立同分布（IID）的保留（held-out）样本上测试其性能。这种方法在培养狭隘专家方面成效显著。但是，图像描述模型 (Lake et al., 2017)、阅读理解系统 (Jia & Liang, 2017) 以及图像分类器 (Alcorn et al., 2018) 在面对输入的多样性和变化性时往往表现出不稳定的行为，这凸显了该方法的局限性。

我们怀疑，在单一领域数据集上进行单任务训练的普遍做法，是导致当前系统缺乏泛化能力的主要原因。利用现有架构向稳健（robust）系统迈进，很可能需要我们在广泛的领域和任务上进行训练并衡量性能。最近，学界已经提出了诸如 GLUE (Wang et al., 2018) 和 decaNLP (McCann et al., 2018) 等多个基准来开始研究这一问题。

多任务学习（Multitask learning）(Caruana, 1997) 是提升通用性能的一个有前景的框架。然而，自然语言处理（NLP）中的多任务训练仍处于起步阶段。近期的研究报告了温和的性能提升 (Yogatama et al., 2019)，而迄今为止最具雄心的两项工作分别仅在总计 10 个和 17 个 (数据集，目标函数)（(dataset, objective)）对上进行了训练 (McCann et al., 2018) (Bowman et al., 2018)。从元学习（meta-learning）的视角来看，每一个 (dataset, objective) 对都只是从数据集和目标函数的分布中采样出的单个训练样本。当前的机器学习系统需要数百到数千个样本才能归纳出泛化良好的函数。这意味着，使用现有方法进行多任务训练，可能同样需要如此多数量级的有效训练对才能实现其潜力。若要靠现有技术强行突破，继续扩大数据集创建和目标函数设计的规模将极其困难。这促使我们探索执行多任务学习的其他设置。

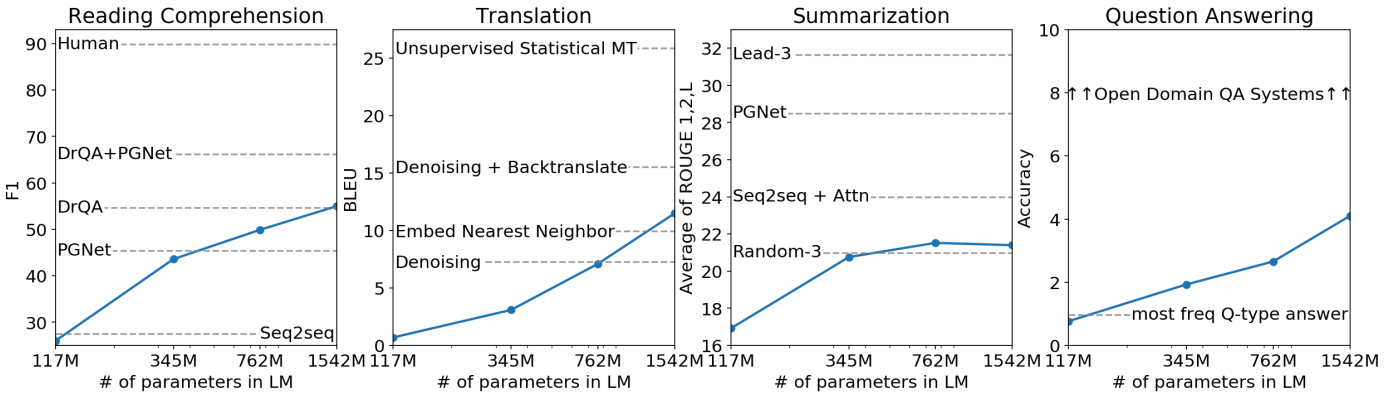


图 ***1 (Figure 1).*** WebText 语言模型在众多 NLP 任务上的零样本任务性能随模型规模变化的函数关系。阅读理解（Reading Comprehension）结果基于 CoQA (Reddy et al., 2018)，翻译（Translation）基于 WMT-14 法译英 (Artetxe et al., 2017)，摘要（Summarization）基于 CNN and Daily Mail (See et al., 2017)，问答（Question Answering）基于 Natural Questions (Kwiatkowski et al., 2019)。第 3 节包含对每项结果的详细描述。

目前在语言任务上表现最好的系统采用了预训练（pre-training）与监督微调（supervised fine-tuning）相结合的方法。这一方法历史悠久，且呈现出向更灵活的迁移形式演进的趋势。起初，人们学习词向量并将其作为任务特定架构的输入 (Mikolov et al., 2013) (Collobert et al., 2011)；随后，循环神经网络的上下文表示被用于迁移 (Dai & Le, 2015) (Peters et al., 2018)；而近期的研究表明，任务特定的架构已不再必要，直接迁移多层自注意力块（self-attention blocks）就已足够 (Radford et al., 2018) (Devlin et al., 2018)。

这些方法仍然需要监督训练才能执行任务。当只有极少甚至没有监督数据可用时，另一条研究路线展示了语言模型执行特定任务的潜力，例如常识推理 (Schwartz et al., 2017) 和情感分析 (Radford et al., 2017)。

在本文中，我们将这两条研究路线连接起来，并延续更通用迁移方法的趋势。我们证明，语言模型可以在零样本设置（zero-shot setting）下执行下游任务——无需对参数或架构进行任何修改。我们通过重点展示语言模型在零样本设置下执行广泛任务的能力，证明了这种方法极具潜力。根据任务的不同，我们取得了有前景的、具竞争力的乃至最先进的（SOTA）结果。

2. 方法 (Approach)

我们方法的核心是语言建模（language modeling）。语言建模通常被构建为从一组样本 $(x_1, x_2, ..., x_n)$ 中进行无监督分布估计，其中每个样本由可变长度的符号序列 $(s_1, s_2, ..., s_n)$ 组成。由于语言具有天然的顺序性，通常将符号上的联合概率分解为条件概率的乘积 (Jelinek & Mercer, 1980) (Bengio et al., 2003)：

$$p(x) = \prod_{i=1}^{n} p(s_n \mid s_1, ..., s_{n-1}) \qquad (1)$$

这种方法使得从 $p(x)$ 以及任何形如 $p(s_{n-k}, ..., s_n \mid s_1, ..., s_{n-k-1})$ 的条件分布中进行采样和估计变得易于处理（tractable）。近年来，能够计算这些条件概率的模型在表达能力上取得了显著进步，例如像 Transformer 这样的自注意力架构 (Vaswani et al., 2017)。

学习执行单个任务可以在概率框架下表示为估计条件分布 $p(output \mid input)$。由于通用系统应当能够执行许多不同的任务（即便面对相同的输入），因此它不仅应当以输入为条件，还应当以所要执行的任务为条件。也就是说，它应当建模 $p(output \mid input, task)$。在多任务和元学习设置中，这一点已有多种形式化方式。任务条件化（task conditioning）通常在架构层面上实现，例如 (Kaiser et al., 2017) 中的任务特定编码器和解码器；或者在算法层面上实现，例如 MAML (Finn et al., 2017) 的内外循环优化框架。但正如 McCann et al. (2018) 所展示的那样，语言本身就提供了一种灵活的方式，可以将任务、输入和输出统统指定为符号序列。例如，一个翻译训练样本可以写成序列 `(translate to french, english text, french text)`（译为法语，英文文本，法文文本）。同样地，一个阅读理解训练样本可以写成 `(answer the question, document, question, answer)`（回答问题，文档，问题，答案）。McCann et al. (2018) 证明了可以训练单个模型 MQAN，在具有这种格式的样本上推断并执行许多不同的任务。

原则上，语言建模也能够学习 McCann et al. (2018) 的任务，而无需显式监督哪些符号是有待预测的输出。由于监督目标与无监督目标完全相同，只是仅在序列的一个子集上进行评估，因此无监督目标的全局最小值也是监督目标的全局最小值。在这种略显简化（toy）的设置中，(Sutskever et al., 2015) 所讨论的将密度估计作为原则性训练目标的顾虑被绕开了。问题转而变成：在实践中，我们是否能够将无监督目标优化至收敛。初步实验证实，足够大的语言模型能够在这个简化设置中执行多任务学习，但学习速度比显式监督方法慢得多。

"I'm not the cleverest man in the world, but like they say in French: **Je ne suis pas un imbecile** [I'm not a fool].
【译：我不是世界上最聪明的人，但正如法语里所说：**Je ne suis pas un imbecile**［我不是傻瓜］。】

In a now-deleted post from Aug. 16, Soheil Eid, Tory candidate in the riding of Joliette, wrote in French: **"Mentez mentez, il en restera toujours quelque chose,"** which translates as, **"Lie lie and something will always remain."**
【译：在 8 月 16 日一条现已删除的帖子中，Joliette 选区的保守党候选人 Soheil Eid 用法语写道：**"Mentez mentez, il en restera toujours quelque chose,"** 翻译过来就是：**"**谎言说上千遍，总会留下点痕迹。**"**】

"I hate the word '**perfume**,'" Burr says. 'It's somewhat better in French: '**parfum**.'
【译："我讨厌'**perfume**（香水）'这个词，"Burr 说。"用法语说稍微好听点：'**parfum**'。"】

If listened carefully at 29:55, a conversation can be heard between two guys in French: "**-Comment on fait pour aller de l'autre côté? -Quel autre côté?**", which means "**- How do you get to the other side? - What side?**".
【译：如果在 29:55 处仔细听，可以听到两个男人用法语对话："**-Comment on fait pour aller de l'autre côté? -Quel autre côté?**"，意思是"**-** 你怎么去另一边？ **-** 哪一边？"。】

If this sounds like a bit of a stretch, consider this question in French: **As-tu aller au cinéma?**, or **Did you go to the movies?**, which literally translates as Have-you to go to movies/theater?
【译：如果这听起来有点牵强，不妨看看这个法语问题：**As-tu aller au cinéma?**，即 **Did you go to the movies?**（你去看电影了吗？），字面直译为 Have-you to go to movies/theater?】

"**Brevet Sans Garantie Du Gouvernement**", translated to English: "**Patented without government warranty**".
【译："**Brevet Sans Garantie Du Gouvernement**"，翻译成英语为："**Patented without government warranty**（获得专利但无政府担保）"。】

表 ***1 (Table 1).*** 在整个 WebText 训练集中发现的自然出现的英译法和法译英翻译演示样本。

虽然从上述定义良好的设置跨越到杂乱无章的"真实自然语言（language in the wild）"是一大步，但 Weston (2016) 在对话背景下论证了开发能够直接从自然语言中学习的系统的必要性，并展示了一个概念验证——通过对教师输出的前向预测，在没有奖励信号的情况下学习问答（QA）任务。尽管对话是一种吸引人的方法，但我们担心它过于受限。互联网包含了海量无需交互式通信即可被动获取的信息。我们的推测是，一个具有足够容量的语言模型为了更好地预测自然语言序列，将会开始学习推断并执行其中所演示的任务，无论这些序列是如何获取的。如果语言模型能够做到这一点，它实际上就是在执行无监督多任务学习。我们通过分析语言模型在零样本设置下于广泛任务上的性能，来检验事实是否如此。

2.1. 训练数据集 (Training Dataset)

以往大多数工作都在单一领域的文本上训练语言模型，例如新闻文章 (Jozefowicz et al., 2016)、维基百科 (Merity et al., 2016) 或小说书籍 (Kiros et al., 2015)。我们的方法要求构建尽可能庞大且多样化的数据集，以便在尽可能丰富的领域和上下文中收集任务的自然语言演示。

网页抓取数据（如 Common Crawl）是一个极具前景、多样化且近乎无限的文本来源。虽然这些归档数据比现有的语言建模数据集大好几个数量级，但它们存在严重的数据质量问题。Trinh & Le (2018) 在其常识推理研究中使用了 Common Crawl，但指出其中有大量文档"内容几乎无法理解"。我们在使用 Common Crawl 进行初步实验时也观察到了类似的数据问题。Trinh & Le (2018) 的最佳结果是使用 Common Crawl 的一个小规模子集取得的，该子集仅包含与他们的目标数据集（威诺格拉德模式挑战赛，Winograd Schema Challenge）最相似的文档。虽然这是提高特定任务性能的务实做法，但我们希望避免预先对所要执行的任务做出假设。

相反，我们创建了一个强调文档质量的新网页抓取数据集。为此，我们只抓取经过人类筛选/过滤的网页。手动过滤完整的网页抓取数据成本高昂得惊人，因此作为起点，我们抓取了社交媒体平台 Reddit 上所有获得至少 3 点赞同度（karma）的外链。这可以被视为一个启发式指标，表明其他用户觉得该链接有趣、有教育意义或单纯很好笑。

由此产生的数据集 **WebText** 包含了这 4500 万个链接的文本子集。为了从 HTML 响应中提取文本，我们结合使用了 Dragnet (Peters & Lecocq, 2013) 和 Newspaper[1] 内容提取器。本文展示的所有结果均使用 WebText 的初步版本，该版本不包含 2017 年 12 月之后创建的链接；经过去重和一些基于启发式规则的清洗后，它包含略多于 800 万篇文档，总计 40 GB 的文本。我们从 WebText 中移除了所有维基百科文档，因为维基百科是其他数据集常见的数据来源，训练数据与测试评估任务的重叠可能会使分析复杂化。

[1] https://github.com/codelucas/newspaper

2.2. 输入表示 (Input Representation)

通用语言模型（LM）应当能够计算任何字符串的概率（并生成任何字符串）。当前的大规模语言模型包含诸如转小写、分词（tokenization）以及词表外（out-of-vocabulary）词元等预处理步骤，这限制了可建模字符串的空间。虽然将 Unicode 字符串作为 UTF-8 字节序列处理能够优雅地满足这一要求（如 Gillick et al. (2015) 等工作所示），但目前的字节级（byte-level）语言模型在诸如十亿词基准（One Billion Word Benchmark）(Al-Rfou et al., 2018) 等大规模数据集上与词级（word-level）语言模型相比缺乏竞争力。我们在尝试于 WebText 上训练标准字节级语言模型时，也观察到了类似的性能差距。

字节对编码（Byte Pair Encoding，BPE）(Sennrich et al., 2015) 是字符级和词级语言建模之间的一种实用折中方案，它有效地在高频符号序列的词级输入与低频符号序列的字符级输入之间进行了插值。尽管名为“字节对编码”，但参考 BPE 实现通常在 Unicode 码位（code points）而非字节序列上运行。这些实现需要包含完整的 Unicode 符号空间才能对所有 Unicode 字符串进行建模。在添加任何多符号词元之前，这就会产生超过 130,000 的基础词表。与 BPE 常使用的 32,000 到 64,000 词元词表相比，这一规模大得令人望而却步。相比之下，字节级版本的 BPE 只需要大小为 256 的基础词表。然而，由于 BPE 使用基于贪心频率的启发式算法来构建词元词表，直接将 BPE 应用于字节序列会导致次优的合并。我们观察到 BPE 包含了常见词（如 dog）的许多变体，因为它们以诸如 dog.、dog!、dog? 等多种形式出现。这导致有限的词表槽位和模型容量得到了次优分配。为了避免这种情况，我们阻止 BPE 对任何字节序列跨字符类别进行合并。我们为空格添加了一个例外，这显著提高了压缩效率，同时仅增加了极少量的跨多个词表词元的单词碎片化。

这种输入表示使我们能够将词级语言模型的经验优势与字节级方法的通用性结合起来。由于我们的方法可以为任何 Unicode 字符串分配概率，因此我们可以在任何数据集上评估我们的语言模型，无论其预处理、分词或词表大小如何。

参数量 **(Parameters)**	层数 **(Layers)**	d_{model}
117M	12	768
345M	24	1024
762M	36	1280
1542M	48	1600

表 ***2 (Table 2).*** 4 种模型规模的架构超参数。

2.3. 模型 (Model)

我们的语言模型使用基于 Transformer (Vaswani et al., 2017) 的架构。该模型很大程度上遵循了 OpenAI GPT 模型 (Radford et al., 2018) 的细节，但做了几处修改：层归一化（Layer normalization）(Ba et al., 2016) 被移到了每个子块的输入端，类似于预激活残差网络（pre-activation residual network）(He et al., 2016)，并且在最后一个自注意力块之后额外添加了一个层归一化。我们采用了一种改进的初始化方法，以考虑残差路径上随模型深度增加而产生的累积效应：在初始化时，我们将残差层的权重按 $1/\sqrt{N}$ 的因子进行缩放，其中 N 是残差层的数量。词表扩展到了 50,257。我们还将上下文大小从 512 增加到 1024 个词元，并使用了更大的批次大小（batchsize = 512）。

3. 实验 (Experiments)

我们训练并测试了四个规模呈近似对数均匀分布的语言模型。其架构总结于表 2 中。最小的模型与原始 GPT 相当，第二小的模型与 BERT (Devlin et al., 2018) 中最大的模型相当。我们最大的模型（称为 **GPT-2**）的参数量比 GPT 多出一个数量级以上。每个模型的学习率均在 WebText 的 5% 保留样本上针对最佳困惑度（perplexity）进行了手动调优。所有模型仍然对 WebText 欠拟合，且随着训练时间的增加，保留集上的困惑度迄今仍在继续改善。

3.1. 语言建模 (Language Modeling)

作为迈向零样本任务迁移的第一步，我们感兴趣的是了解 WebText 语言模型在其受训的主任务——语言建模——上的零样本领域迁移表现如何。由于我们的模型在字节级别上运行，不需要有损的预处理或分词，因此我们可以在任何语言模型基准上对其进行评估。语言建模数据集上的结果通常以每个规范预测单元（canonical prediction unit，通常是字符、字节或单词）的平均负对数概率的缩放或指数化形式来报告。我们通过根据 WebText 语言模型计算数据集的对数概率，并除以规范单元的数量来评估相同的指标。对于其中许多数据集而言，WebText 语言模型将在显著偏离分布（out-of-distribution）的情况下接受测试，不得不预测经过激进标准化的文本、分词伪影（如断开的标点符号和缩略形式）、打乱顺序的句子，甚至是字符串 <UNK> ——它在 WebText 中极其罕见，在 400 亿字节中仅出现过 26 次。我们在表 3 中使用可逆去分词器（invertible de-tokenizers）报告主要结果，这些去分词器尽可能多地移除了这些分词/预处理伪影。由于这些去分词器是可逆的，我们仍然可以计算数据集的对数概率，它们可以被视为一种简单形式的领域自适应。使用这些去分词器后，我们观察到 GPT-2 获得了 2.5 到 5 的困惑度提升。

	LAMBADA (PPL)	LAMBADA (ACC)	CBT-CN (ACC)	CBT-NE (ACC)	WikiText2 (PPL)	PTB (PPL)	enwik8 (BPB)	text8 (BPC)	WikiText103 (PPL)	1BW (PPL)
SOTA	99.8	59.23	85.7	82.3	39.14	46.54	0.99	1.08	18.3	**21.8**
117M	**35.13**	45.99	**87.65**	**83.4**	**29.41**	65.85	1.16	1.17	37.50	75.20
345M	**15.60**	55.48	**92.35**	**87.1**	**22.76**	47.33	1.01	**1.06**	26.37	55.72
762M	**10.87**	**60.12**	**93.45**	**88.0**	**19.93**	**40.31**	**0.97**	**1.02**	22.05	44.575
1542M	**8.63**	**63.24**	**93.30**	**89.05**	**18.34**	**35.76**	**0.93**	**0.98**	**17.48**	42.16

表 ***3 (Table 3).*** 多个数据集上的零样本结果。所有这些结果均未进行任何训练或微调。PTB 和 WikiText-2 结果来自 (Gong et al., 2018)。CBT 结果来自 (Bajgar et al., 2016)。LAMBADA 准确率结果来自 (Hoang et al., 2018)，LAMBADA 困惑度结果来自 (Grave et al., 2016)。其他结果来自 (Dai et al., 2019)。

WebText 语言模型在跨领域和跨数据集时迁移表现良好，在零样本设置下刷新了 8 个数据集中 7 个的最先进（SOTA）水平。在仅有 100 万到 200 万训练词元的小型数据集（如 Penn Treebank 和 WikiText-2）上注意到了大幅提升。在旨在衡量长期依赖关系而创建的数据集（如 LAMBADA (Paperno et al., 2016) 和儿童读物测试 Children's Book Test (Hill et al., 2015)）上也注意到了显著改进。在十亿词基准（One Billion Word Benchmark, 1BW）(Chelba et al., 2013) 上，我们的模型仍然明显逊于先前的工作。这很可能是因为它既是最大的数据集，又具有最具破坏性的预处理——1BW 的句子级随机打乱移除了所有的长程结构。

3.2. 儿童读物测试 (Children's Book Test)

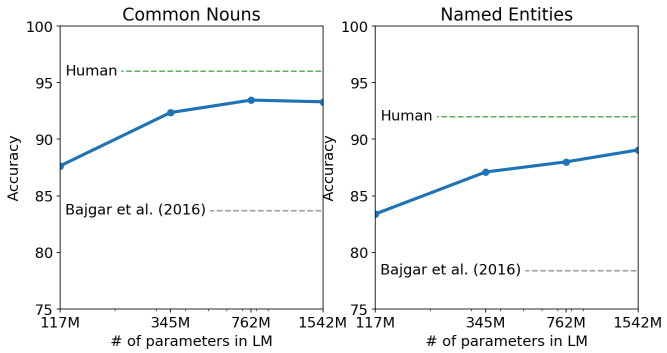


图 ***2 (Figure 2).*** 儿童读物测试（Children's Book Test）上的性能随模型容量变化的函数关系。人类性能数据来自 Bajgar et al. (2016)，而非原论文中低得多的估计值。

儿童读物测试（CBT）(Hill et al., 2015) 旨在检验语言模型在不同类别词汇上的表现：命名实体、名词、动词和介词。CBT 不以困惑度作为评估指标，而是报告自动构建的完形填空测试（cloze test）上的准确率，其任务是从被省略词的 10 个可能候选项中预测哪一个是正确的。遵循原论文引入的语言模型方法，我们根据语言模型计算每个选项以及以该选项为条件的句子其余部分的概率，并预测概率最高的那一个。如图 2 所示，随着模型规模的增加，性能稳步提升，并弥合了该测试上与人类性能的大部分差距。数据重叠分析显示，CBT 测试集中的一本书——鲁德亚德·吉卜林（Rudyard Kipling）的《丛林之书》（*The Jungle Book*）——包含在 WebText 中，因此我们报告没有显著重叠的验证集上的结果。GPT-2 在普通名词上取得了 93.3%、在命名实体上取得了 89.1% 的新 SOTA 结果。我们应用了去分词器以从 CBT 中移除 PTB 风格的分词伪影。

3.3. LAMBADA

LAMBADA 数据集 (Paperno et al., 2016) 测试系统对文本中长程依赖关系进行建模的能力。其任务是预测句子的最后一个词，而人类需要至少 50 个词元的上下文才能成功预测这些词。GPT-2 将最先进（SOTA）困惑度从 99.8 (Grave et al., 2016) 提升至 8.6，并将语言模型在该测试上的准确率从 19% (Dehghani et al., 2018) 提高到了 52.66%。对 GPT-2 错误的调查显示，大多数预测都是句子的有效延续，但并非有效的句末词。这表明语言模型没有利用"该词必须是句子最后一个词"这一额外有用约束。添加停用词过滤器（stop-word filter）作为对该约束的近似，进一步将准确率提升至 63.24%，使该任务的整体最先进水平提高了 4%。先前的最先进方法 (Hoang et al., 2018) 使用了不同的受限预测设置，即将模型的输出限制为仅限上下文中出现过的词。对于 GPT-2 而言，这一限制反而有害而非有益，因为有 19% 的答案并不在上下文中。我们使用的是未经预处理版本的数据集。

3.4. 威诺格拉德模式挑战赛 (Winograd Schema Challenge)

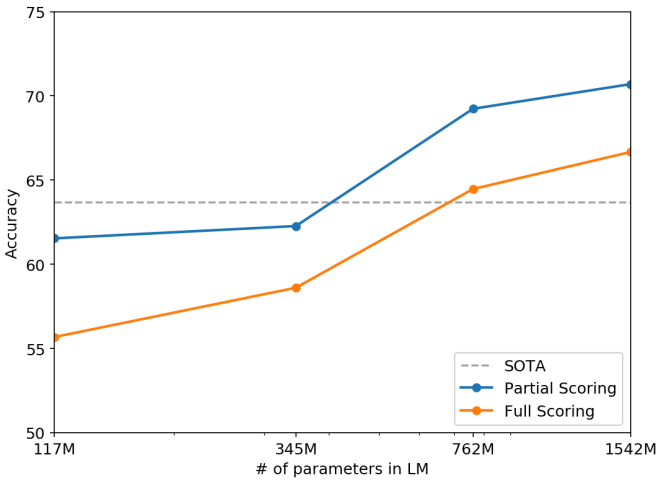


图 ***3 (Figure 3).*** 威诺格拉德模式挑战赛上的性能随模型容量变化的函数关系。

威诺格拉德模式挑战赛（Winograd Schema Challenge）(Levesque et al., 2012) 旨在通过衡量系统消解文本歧义的能力，来测试其执行常识推理的能力。最近，Trinh & Le (2018) 通过使用语言模型以更高概率预测歧义的消解方案，在该挑战赛上展示了重大进展。我们遵循他们的问题表述，并在图 3 中可视化了我们的模型在完整评分（full scoring）和部分评分（partial scoring）技术下的表现。GPT-2 将最先进准确率提高了 7%，达到 70.70%。该数据集相当小，仅有 273 个样本，因此我们建议阅读 Trichelair et al. (2018) 以帮助理解这一结果的背景。

3.5. 阅读理解 (Reading Comprehension)

对话问答数据集（CoQA）(Reddy et al., 2018) 由来自 7 个不同领域的文档组成，每篇文档配有提问者和回答者之间围绕该文档展开的自然语言对话。CoQA 既测试阅读理解能力，也测试模型回答依赖对话历史的问题（如“Why?”）的能力。

当以文档、相关对话的历史记录以及末尾词元 `A:` 为条件时，对 GPT-2 进行贪心解码在开发集上取得了 55 的 F1 分数。这在不使用基线模型训练所用的 127,000+ 个人工收集问答对的情况下，匹配或超过了 4 个基线系统中的 3 个。目前监督学习的 SOTA（一个基于 BERT 的系统 (Devlin et al., 2018)）已接近人类 89 F1 的表现。虽然对于一个没有任何监督训练的系统而言，GPT-2 的表现令人振奋，但对其答案和错误的一些检查表明，GPT-2 经常使用简单的基于检索的启发式策略，例如在回答“谁（who）”的问题时直接用文档中的一个人名作答。

模型 / 方法	R-1	R-2	R-L	R-AVG
Bottom-Up Sum	**41.22**	**18.68**	**38.34**	**32.75**
Lede-3	40.38	17.66	36.62	31.55
Seq2Seq + Attn	31.33	11.81	28.83	23.99
GPT-2 `TL;DR:`	29.34	8.27	26.58	21.40
Random-3	28.78	8.63	25.52	20.98
GPT-2 无提示 (no hint)	21.58	4.03	19.47	15.03

表 ***4 (Table 4).*** 在 CNN and Daily Mail 数据集上以 ROUGE F1 指标衡量的摘要性能。Bottom-Up Sum 是来自 (Gehrmann et al., 2018) 的 SOTA 模型。

3.6. 文本摘要 (Summarization)

我们在 CNN and Daily Mail 数据集 (Nallapati et al., 2016) 上测试了 GPT-2 执行摘要的能力。为了诱导摘要行为，我们在文章末尾添加文本 `TL;DR:`，并使用 $k = 2$ 的 Top-k 随机采样 (Fan et al., 2018) 生成 100 个词元——相比贪心解码，这能减少重复并鼓励生成更具概括性（abstractive）的摘要。我们将这 100 个词元中生成的前 3 个句子作为摘要。虽然定性来看，生成的内容很像摘要（如表 14 所示），但它们往往聚焦于文章后半部分的内容，或者混淆具体细节（例如车祸涉及多少辆车，或者标志是在帽子上还是衬衫上）。在常报告的 ROUGE 1、2、L 指标上，生成的摘要才刚刚开始接近经典神经网络基线的性能，仅比从文章中随机选择 3 个句子略好一点。当移除任务提示（`TL;DR:`）时，GPT-2 在综合指标上的表现下降了 6.4 分，这证明了通过自然语言在语言模型中激发任务特定行为的能力。

3.7. 机器翻译 (Translation)

我们测试了 GPT-2 是否已经开始学习如何将一种语言翻译成另一种语言。为了帮助它推断出这是期望的任务，我们以格式为 `english sentence = french sentence` 的样本对上下文作为语言模型的条件，然后在最后的提示 `english sentence =` 之后，使用贪心解码从模型中采样，并将生成的第一个句子作为译文。在 WMT-14 英译法测试集上，GPT-2 获得了 5 BLEU，这比先前无监督词翻译研究 (Conneau et al., 2017b) 中通过双语词典推断出的逐词替换结果略差。

问题 **(Question)**	生成的答案 **(Generated Answer)**	正确性	概率 **(Probability)**
Who wrote the book the origin of species? (《物种起源》一书是谁写的？)	Charles Darwin (查尔斯·达尔文)	✓	83.4%
Who is the founder of the ubuntu project? (Ubuntu 项目的创始人是谁？)	Mark Shuttleworth (马克·沙特尔沃思)	✓	82.0%
Who is the quarterback for the green bay packers? (绿湾包装工队的四分卫是谁？)	Aaron Rodgers (阿隆·罗杰斯)	✓	81.1%
Panda is a national animal of which country? (熊猫是哪个国家的国宝？)	China (中国)	✓	76.8%
Who came up with the theory of relativity? (谁提出了相对论？)	Albert Einstein (阿尔伯特·爱因斯坦)	✓	76.4%
When was the first star wars film released? (第一部《星球大战》电影是何时上映的？)	1977	✓	71.4%
What is the most common blood type in sweden? (瑞典最常见的血型是什么？)	A	✗	70.6%
Who is regarded as the founder of psychoanalysis? (谁被尊为精神分析学派的创始人？)	Sigmund Freud (西格蒙德·弗洛伊德)	✓	69.3%
Who took the first steps on the moon in 1969? (1969 年谁在月球上迈出了第一步？)	Neil Armstrong (尼尔·阿姆斯特朗)	✓	66.8%
Who is the largest supermarket chain in the uk? (英国最大的连锁超市是谁？)	Tesco (乐购)	✓	65.3%
What is the meaning of shalom in english? (shalom 在英语中是什么意思？)	peace (和平/平安)	✓	64.0%
Who was the author of the art of war? (《孙子兵法》的作者是谁？)	Sun Tzu (孙子)	✓	59.6%
Largest state in the us by land mass? (美国陆地面积最大的州？)	California (加利福尼亚州)	✗	59.2%
Green algae is an example of which type of reproduction? (绿藻是哪种繁殖方式的例子？)	parthenogenesis (孤雌生殖)	✗	56.5%
Vikram samvat calender is official in which country? (维克拉姆历是哪个国家的官方历法？)	India (印度)	✓	55.6%
Who is mostly responsible for writing the declaration of independence? (谁主要负责起草《独立宣言》？)	Thomas Jefferson (托马斯·杰斐逊)	✓	53.3%
What us state forms the western boundary of montana? (美国哪个州构成了蒙大拿州的西部边界？)	Montana (蒙大拿州)	✗	52.3%
Who plays ser davos in game of thrones? (在《权力的游戏》中谁饰演戴佛斯爵士？)	Peter Dinklage (彼特·丁拉基)	✗	52.1%
Who appoints the chair of the federal reserve system? (谁任命美联储主席？)	Janet Yellen (珍妮特·耶伦)	✗	51.5%
State the process that divides one nucleus into two genetically identical nuclei? (将细胞核分裂为两个遗传相同细胞核的过程？)	mitosis (有丝分裂)	✓	50.7%
Who won the most mvp awards in the nba? (谁在 NBA 赢得了最多的 MVP 奖项？)	Michael Jordan (迈克尔·乔丹)	✗	50.2%
What river is associated with the city of rome? (哪条河流与罗马城息息相关？)	the Tiber (台伯河)	✓	48.6%
Who is the first president to be impeached? (第一位被弹劾的总统是谁？)	Andrew Johnson (安德鲁·约翰逊)	✓	48.3%
Who is the head of the department of homeland security 2017? (2017 年国土安全部部长是谁？)	John Kelly (约翰·凯利)	✓	47.0%
What is the name given to the common currency to the european union? (欧盟通用货币的名称是什么？)	Euro (欧元)	✓	46.8%
What was the emperor name in star wars? (《星球大战》中皇帝的名字是什么？)	Palpatine (帕尔帕廷)	✓	46.5%
Do you have to have a gun permit to shoot at a range? (在靶场射击必须持有持枪证吗？)	No (不需要)	✓	46.4%
Who proposed evolution in 1859 as the basis of biological development? (谁在 1859 年提出进化论作为生物发展的基础？)	Charles Darwin (查尔斯·达尔文)	✓	45.7%
Nuclear power plant that blew up in russia? (在俄国［前苏联］发生爆炸的核电站？)	Chernobyl (切尔诺贝利)	✓	45.7%
Who played john connor in the original terminator? (在原版《终结者》中谁饰演约翰·康纳？)	Arnold Schwarzenegger (阿诺德·施瓦辛格)	✗	45.2%

表 ***5 (Table 5).*** GPT-2 在 Natural Questions 开发集上生成的最有把握（置信度最高）的 30 个答案，按 GPT-2 给出的概率排序。根据第 4 节描述的程序检测，这些问题均未出现在 WebText 中。

在 WMT-14 法译英测试集上，GPT-2 能够利用其非常强大的英语语言模型取得显著更好的表现，达到了 11.5 BLEU。这超过了来自 (Artetxe et al., 2017) 和 (Lample et al., 2017) 的几个无监督机器翻译基线，但仍远逊于当前最佳无监督机器翻译方法 (Artetxe et al., 2019) 的 33.5 BLEU。该任务上的表现令我们感到惊讶，因为作为过滤步骤，我们刻意从 WebText 中移除了非英语网页。为了证实这一点，我们在 WebText 上运行了一个字节级语言检测器[2]，仅检测出 10MB 的法语数据，这比先前无监督机器翻译研究中常见的单语法语语料库小约 500 倍。

[2] https://github.com/CLD2Owners/cld2

3.8. 问答 (Question Answering)

测试语言模型内部包含哪些信息的一种潜在方法是评估它生成事实型（factoid-style）问题正确答案的频率。此前在所有信息均存储于参数中的神经系统（例如神经对话模型 *A Neural Conversational Model* (Vinyals & Le, 2015)）中展示这种行为时，由于缺乏高质量的评估数据集，仅报告了定性结果。近期推出的 Natural Questions 数据集 (Kwiatkowski et al., 2019) 是更定量地测试这一点的理想资源。与翻译类似，语言模型的上下文被填入了一些问答对样本作为种子（seed），这有助于模型推断出该数据集简短回答的风格。当使用 SQuAD 等阅读理解数据集常用的精确匹配（exact match）指标进行评估时，GPT-2 正确回答了 4.1% 的问题。[3] 作为对比，最小的模型未能超过一个极其简单的基线的 1.0% 准确率——该基线仅针对每种问题类型（who、what、where 等）返回最常见的答案。GPT-2 正确

回答的问题数量是其 5.3 倍，这表明模型容量一直是制约神经系统在此类任务上表现不佳的主要因素。GPT-2 为其生成答案分配的概率具有良好校准（well calibrated），在其最有把握的 1% 问题上，GPT-2 的准确率达到了 63.1%。GPT-2 在开发集问题上生成的最有把握的 30 个答案如表 5 所示。尽管如此，GPT-2 的性能仍然远远逊色于将信息检索与抽取式文档问答相结合的开放域问答系统（30% 到 50% 的范围）(Alberti et al., 2019)。

[3] 此前自认为擅长随机冷知识问答的 Alec，在与 GPT-2 相同的设置下对随机抽样的 100 个样本进行测试，答对了其中的 17 个。实际上他只答对了 14 个，但另外 3 个他本该答对的。

训练集	PTB	WikiText-2	enwik8	text8	Wikitext-103	1BW
数据集自身训练集 (Dataset train)	**2.67%**	0.66%	**7.50%**	2.34%	**9.09%**	**13.19%**
WebText 训练集 (WebText train)	0.88%	**1.63%**	6.31%	**3.94%**	2.42%	3.75%

表 ***6 (Table 6).*** 测试集 8-gram 与训练集重叠的百分比。

4. 泛化与记忆 (Generalization vs Memorization)

计算机视觉领域的近期研究表明，常见的图像数据集包含相当数量的近似重复图像。例如，CIFAR-10 的训练图像和测试图像之间存在 3.3% 的重叠 (Barz & Denzler, 2019)。这导致对机器学习系统泛化性能的高估。随着数据集规模的增加，这一问题变得越来越可能发生，这表明 WebText 也可能发生类似的现象。因此，分析有多少测试数据也出现在了训练数据中至关重要。

为了研究这一点，我们创建了包含 WebText 训练集词元 8-gram 的布隆过滤器（Bloom filters）。为了提高召回率，字符串被归一化为仅包含以单个空格作为分隔符的小写字母数字单词。布隆过滤器的构造使得假阳性率（false positive rate）的上界为 $1/10^8$。我们通过生成 100 万个字符串进一步验证了这一低假阳性率，其中过滤器检出的数量为零。

给定一个数据集，这些布隆过滤器允许我们计算该数据集中同样出现在 WebText 训练集中的 8-gram 百分比。表 6 展示了常见语言模型基准测试集的重叠分析结果。常见语言模型数据集的测试集与 WebText 训练集之间存在 1%–6% 的重叠，平均重叠率为 3.2%。有些令人惊讶的是，许多数据集与它们自身的训练划分具有更大的重叠，平均重叠率达 5.9%。

我们的方法针对召回率进行了优化，尽管对重叠部分的人工检查显示出许多常见短语，但也有许多较长的匹配是由重复数据引起的。这并非 WebText 所独有。例如，我们发现 WikiText-103 的测试集中有一篇文章也出现在其训练数据集中。由于测试集中只有 60 篇文章，这意味着至少存在 1.6% 的重叠。[4] 潜在更令人担忧的是，根据我们的程序，1BW 与其自身训练集的重叠率接近 13.2%。

对于威诺格拉德模式挑战赛，我们发现仅有 10 个模式（schemata）与 WebText 训练集存在任何 8-gram 重叠。其中 2 个是伪匹配（spurious matches）。在其余 8 个中，只有 1 个模式出现在任何泄露了答案的上下文中。

对于 CoQA，新闻领域中约有 15% 的文档已经存在于 WebText 中，模型在这些文档上的表现高出约 3 个 F1。CoQA 的开发集指标报告的是 5 个不同领域的平均表现，我们测得跨各个领域因数据重叠带来的增益约为 0.5–1.0 F1。不过，WebText 中没有任何实际的训练问题或答案，因为 CoQA 是在 WebText 链接截止日期之后发布的。

在 LAMBADA 上，平均重叠率为 1.2%。GPT-2 在重叠率大于 15% 的样本上表现好约 2 个困惑度。排除所有存在任何重叠的样本后重新计算指标，结果从 8.6 变为 8.7 困惑度，准确率从 63.2% 降至 62.9%。整体结果的这一极小变化很可能是因为每 200 个样本中只有 1 个存在显著重叠。

总体而言，我们的分析表明，WebText 训练数据与特定评估数据集之间的数据重叠为所报告的结果提供了微小但一致的收益。然而，正表 6 所突出的那样，对于大多数数据集，我们并未注意到比标准训练集和测试集之间原本已存在的重叠大得多的重叠。

[4] 相当一部分额外重叠是由于编辑在具有共同主题（如朝鲜战争中的各场战役）的多篇文章之间复用了部分段落。

理解和量化高度相似的文本如何影响性能是一个重要的研究问题。更好的去重技术（如可扩展的模糊匹配）也有助于更好地回答这些问题。目前，我们建议在为新的 NLP 数据集创建训练和测试划分时，使用基于 n-gram 重叠的去重作为重要的验证步骤和健全性检查（sanity check）。

判断 WebText 语言模型的性能是否归因于记忆的另一种潜在方法，是检查它们在自身保留集（held-out set）上的表现。如图 4 所示，WebText 训练集和测试集上的性能十分相似，并且随着模型规模的增加而共同提升。这表明即便 GPT-2 在很多方面仍然对 WebText 欠拟合。

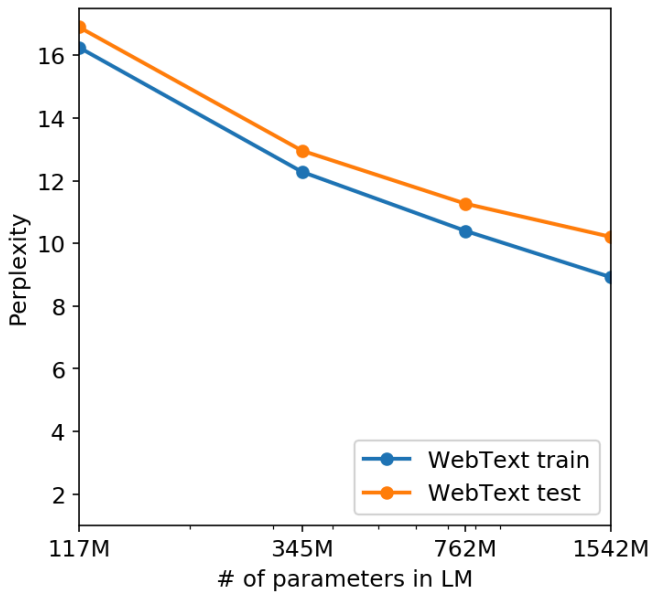


图 ***4 (Figure 4).*** 在 WebText 上训练的语言模型性能随模型规模变化的函数关系。

GPT-2 还能够撰写关于发现会说话的独角兽的新闻文章。表 13 中提供了一个示例。

5. 相关工作 (Related Work)

本工作的很大一部分衡量了在更大数据集上训练的更大语言模型的性能。这与 Jozefowicz et al. (2016) 在十亿词基准（1 Billion Word Benchmark）上扩展基于 RNN 的语言模型的工作类似。Bajgar et al. (2016) 此前也通过利用古腾堡计划（Project Gutenberg）构建大得多的训练数据集来补充标准训练数据集，从而改进了儿童读物测试（Children's Book Test）上的结果。Hestness et al. (2017) 对各种深度学习模型的性能如何随模型容量和数据集规模两者变化进行了全面分析。我们的实验虽然在跨任务时噪声大得多，但表明类似的趋势对于目标函数的子任务同样成立，并且延续到了 10 亿+（1B+）参数规模区间。

生成模型中学到的有趣功能此前已有文献记载，例如 RNN 语言模型中的单元能够执行行宽跟踪和引语/注释检测 (Karpathy et al., 2015)。对我们的工作更具启发性的是 Liu et al. (2018) 的观察：一个受训用于生成维基百科文章的模型也学会了在不同语言之间翻译人名。

先前的工作还探索了过滤和构建大型网页文本语料库的替代方法，例如 iWeb 语料库 (Davies, 2018)。

关于语言任务的预训练方法已有大量研究。除了引言中提到的工作外，GloVe (Pennington et al., 2014) 将词向量表示学习扩展到了整个 Common Crawl。文本深度表示学习的一项有影响力的早期工作是 Skip-thought Vectors (Kiros et al., 2015)。McCann et al. (2017) 探索了使用源自机器翻译模型的表示，而 Howard & Ruder (2018) 改进了 (Dai & Le, 2015) 基于 RNN 的微调方法。(Conneau et al., 2017a) 研究了自然语言推理模型所学表示的迁移性能，(Subramanian et al., 2018) 则探索了大规模多任务训练。

(Ramachandran et al., 2016) 证明了 seq2seq 模型受益于使用预训练语言模型作为编码器和解码器的初始化。更近期的研究表明，当针对闲聊对话和基于对话的问答系统等困难生成任务进行微调时，语言模型预训练同样很有帮助 (Wolf et al., 2019) (Dinan et al., 2018)。

6. 讨论 (Discussion)

大量研究致力于学习 (Hill et al., 2016)、理解 (Levy & Goldberg, 2014) 和批判性地评估 (Wieting & Kiela, 2019) 监督及无监督预训练方法的表示。我们的结果表明，无监督任务学习是另一个值得探索的有前景的研究领域。这些发现潜在地帮助解释了预训练技术在下游 NLP 任务中取得广泛成功的原因，因为我们展示了在极限情况下，这些预训练技术之一开始直接学习执行任务，而无需监督自适应或修改。

在阅读理解任务上，GPT-2 在零样本设置下的性能与监督基线颇具竞争力。然而，在诸如摘要等其他任务上，尽管它定性地在执行该任务，但根据定量指标衡量，其性能仍然十分初步。虽然作为一项研究结果颇具启发性，但就实际应用而言，GPT-2 的零样本性能距离可用还很遥远。

我们研究了 WebText 语言模型在许多经典 NLP 任务上的零样本性能，但还有许多其他任务可以评估。毫无疑问，在许多实际任务上，GPT-2 的表现仍然不比随机猜测好。即便在我们评估过的常见任务（如问答和翻译）上，语言模型也只有在具备足够容量时才开始超越简单的基线。

虽然零样本性能确立了 GPT-2 在许多任务上的潜在性能基线，但尚不清楚通过微调其上限在哪里。在某些任务上，GPT-2 完全生成式（abstractive）的输出与目前在许多问答和阅读理解数据集上处于最先进水平的基于抽取式指针网络（extractive pointer network）(Vinyals et al., 2015) 的输出大相径庭。鉴于此前微调 GPT 的成功，我们计划研究在 decaNLP 和 GLUE 等基准上进行微调，特别是因为目前尚不清楚 GPT-2 额外的训练数据和容量是否足以克服 BERT (Devlin et al., 2018) 所展示的单向表示的低效性。

7. 结论 (Conclusion)

当大型语言模型在足够庞大且多样化的数据集上进行训练时，它能够在众多领域和数据集上表现出色。GPT-2 在零样本设置下于 8 个受测语言建模数据集中的 7 个上达到了最先进的（SOTA）性能。该模型在零样本设置下能够执行的任务多样性表明，为最大化足够多样化的文本语料库似然而训练的高容量模型，开始学会在无需显式监督的情况下执行数量惊人的任务。[5]

[5] 用于下载和使用小型模型的初步代码发布于 https://github.com/openai/gpt-2

致谢 (Acknowledgements)

感谢所有撰写文本、分享链接并在 WebText 中为内容点赞的人们。数以百万计的人参与创建了训练 GPT-2 所用的数据。同时感谢所有在训练基础设施方面帮助过我们的 Google 员工，包括 Zak Stone、JS Riehl、Jonathan Hseu、Russell Power、Youlong Cheng、Noam Shazeer、Solomon Boulos、Michael Banfield、Aman Gupta、Daniel Sohn 等许多人。最后感谢对论文初稿提供反馈的人们：Jacob Steinhardt、Sam Bowman、Geoffrey Irving 和 Madison May。

参考文献 (References)

Al-Rfou, R., Choe, D., Constant, N., Guo, M., and Jones, L. Character-level language modeling with deeper self-attention. *arXiv preprint arXiv:1808.04444*, 2018.

Alberti, C., Lee, K., and Collins, M. A bert baseline for the natural questions. *arXiv preprint arXiv:1901.08634*, 2019.

Alcorn, M. A., Li, Q., Gong, Z., Wang, C., Mai, L., Ku, W.-S., and Nguyen, A. Strike (with) a pose: Neural networks are easily fooled by strange poses of familiar objects. *arXiv preprint arXiv:1811.11553*, 2018.

Amodei, D., Ananthanarayanan, S., Anubhai, R., Bai, J., Battenberg, E., Case, C., Casper, J., Catanzaro, B., Cheng, Q., Chen, G., et al. Deep speech 2: End-to-end speech recognition in english and mandarin. In *International Conference on Machine Learning*, pp. 173–182, 2016.

Artetxe, M., Labaka, G., Agirre, E., and Cho, K. Unsupervised neural machine translation. *arXiv preprint arXiv:1710.11041*, 2017.

Artetxe, M., Labaka, G., and Agirre, E. An effective approach to unsupervised machine translation. *arXiv preprint arXiv:1902.01313*, 2019.

Ba, J. L., Kiros, J. R., and Hinton, G. E. Layer normalization. *arXiv preprint arXiv:1607.06450*, 2016.

Bajgar, O., Kadlec, R., and Kleindienst, J. Embracing data abundance: Booktest dataset for reading comprehension. *arXiv preprint arXiv:1610.00956*, 2016.

Barz, B. and Denzler, J. Do we train on test data? purging cifar of near-duplicates. *arXiv preprint arXiv:1902.00423*, 2019.

Bengio, Y., Ducharme, R., Vincent, P., and Jauvin, C. A neural probabilistic language model. *Journal of machine learning research*, 3(Feb):1137–1155, 2003.

Bowman, S. R., Pavlick, E., Grave, E., Van Durme, B., Wang, A., Hula, J., Xia, P., Pappagari, R., McCoy, R. T., Patel, R., et al. Looking for elmo's friends: Sentence-level pretraining beyond language modeling. *arXiv preprint arXiv:1812.10860*, 2018.

Caruana, R. Multitask learning. *Machine learning*, 28(1):41–75, 1997.

Chelba, C., Mikolov, T., Schuster, M., Ge, Q., Brants, T., Koehn, P., and Robinson, T. One billion word benchmark for measuring progress in statistical language modeling. *arXiv preprint arXiv:1312.3005*, 2013.

Collobert, R., Weston, J., Bottou, L., Karlen, M., Kavukcuoglu, K., and Kuksa, P. Natural language processing (almost) from scratch. *Journal of Machine Learning Research*, 12(Aug):2493–2537, 2011.

Conneau, A., Kiela, D., Schwenk, H., Barrault, L., and Bordes, A. Supervised learning of universal sentence representations from natural language inference data. *arXiv preprint arXiv:1705.02364*, 2017a.

Conneau, A., Lample, G., Ranzato, M., Denoyer, L., and Jégou, H. Word translation without parallel data. *arXiv preprint arXiv:1710.04087*, 2017b.

Dai, A. M. and Le, Q. V. Semi-supervised sequence learning. In *Advances in neural information processing systems*, pp. 3079–3087, 2015.

Dai, Z., Yang, Z., Yang, Y., Cohen, W. W., Carbonell, J., Le, Q. V., and Salakhutdinov, R. Transformer-xl: Attentive language models beyond a fixed-length context. *arXiv preprint arXiv:1901.02860*, 2019.

Davies, M. The 14 billion word iweb corpus. *https://corpus.byu.edu/iWeb/*, 2018.

Dehghani, M., Gouws, S., Vinyals, O., Uszkoreit, J., and Kaiser, Ł. Universal transformers. *arXiv preprint arXiv:1807.03819*, 2018.

Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*, 2018.

Dinan, E., Roller, S., Shuster, K., Fan, A., Auli, M., and Weston, J. Wizard of wikipedia: Knowledge-powered conversational agents. *arXiv preprint arXiv:1811.01241*, 2018.

Fan, A., Lewis, M., and Dauphin, Y. Hierarchical neural story generation. *arXiv preprint arXiv:1805.04833*, 2018.

Finn, C., Abbeel, P., and Levine, S. Model-agnostic meta-learning for fast adaptation of deep networks. *arXiv preprint arXiv:1703.03400*, 2017.

Gehrmann, S., Deng, Y., and Rush, A. M. Bottom-up abstractive summarization. *arXiv preprint arXiv:1808.10792*, 2018.

Gillick, D., Brunk, C., Vinyals, O., and Subramanya, A. Multilingual language processing from bytes. *arXiv preprint arXiv:1512.00103*, 2015.

Gong, C., He, D., Tan, X., Qin, T., Wang, L., and Liu, T.-Y. Frage: frequency-agnostic word representation. In *Advances in Neural Information Processing Systems*, pp. 1341–1352, 2018.

Grave, E., Joulin, A., and Usunier, N. Improving neural language models with a continuous cache. *arXiv preprint arXiv:1612.04426*, 2016.

He, K., Zhang, X., Ren, S., and Sun, J. Identity mappings in deep residual networks. In *European conference on computer vision*, pp. 630–645. Springer, 2016.

Hestness, J., Narang, S., Ardalani, N., Diamos, G., Jun, H., Kianinejad, H., Patwary, M., Ali, M., Yang, Y., and Zhou, Y. Deep learning scaling is predictable, empirically. *arXiv preprint arXiv:1712.00409*, 2017.

Hill, F., Bordes, A., Chopra, S., and Weston, J. The goldilocks principle: Reading children's books with explicit memory representations. *arXiv preprint arXiv:1511.02301*, 2015.

Hill, F., Cho, K., and Korhonen, A. Learning distributed representations of sentences from unlabelled data. *arXiv preprint arXiv:1602.03483*, 2016.

Hoang, L., Wiseman, S., and Rush, A. M. Entity tracking improves cloze-style reading comprehension. *arXiv preprint arXiv:1810.02891*, 2018.

Howard, J. and Ruder, S. Universal language model fine-tuning for text classification. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, volume 1, pp. 328–339, 2018.

Jelinek, F. and Mercer, R. L. Interpolated estimation of markov source parameters from sparse data. In *Proceedings of the Workshop on*

Pattern Recognition in Practice, Amsterdam, The Netherlands: North-Holland, May., 1980.

Jia, R. and Liang, P. Adversarial examples for evaluating reading comprehension systems. *arXiv preprint arXiv:1707.07328*, 2017.

Jozefowicz, R., Vinyals, O., Schuster, M., Shazeer, N., and Wu, Y. Exploring the limits of language modeling. *arXiv preprint arXiv:1602.02410*, 2016.

Kaiser, L., Gomez, A. N., Shazeer, N., Vaswani, A., Parmar, N., Jones, L., and Uszkoreit, J. One model to learn them all. *arXiv preprint arXiv:1706.05137*, 2017.

Karpathy, A., Johnson, J., and Fei-Fei, L. Visualizing and understanding recurrent networks. *arXiv preprint arXiv:1506.02078*, 2015.

Kirkpatrick, J., Pascanu, R., Rabinowitz, N., Veness, J., Desjardins, G., Rusu, A. A., Milan, K., Quan, J., Ramalho, T., Grabska-Barwinska, A., et al. Overcoming catastrophic forgetting in neural networks. *Proceedings of the national academy of sciences*, pp. 201611835, 2017.

Kiros, R., Zhu, Y., Salakhutdinov, R. R., Zemel, R., Urtasun, R., Torralba, A., and Fidler, S. Skip-thought vectors. In *Advances in neural information processing systems*, pp. 3294–3302, 2015.

Krizhevsky, A., Sutskever, I., and Hinton, G. E. Imagenet classification with deep convolutional neural networks. In *Advances in neural information processing systems*, pp. 1097–1105, 2012.

Kwiatkowski, T., Palomaki, J., Rhinehart, O., Collins, M., Parikh, A., Alberti, C., Epstein, D., Polosukhin, I., Kelcey, M., Devlin, J., et al. Natural questions: a benchmark for question answering research. 2019.

Lake, B. M., Ullman, T. D., Tenenbaum, J. B., and Gershman, S. J. Building machines that learn and think like people. *Behavioral and Brain Sciences*, 40, 2017.

Lample, G., Conneau, A., Denoyer, L., and Ranzato, M. Unsupervised machine translation using monolingual corpora only. *arXiv preprint arXiv:1711.00043*, 2017.

Levesque, H., Davis, E., and Morgenstern, L. The winograd schema challenge. In *Thirteenth International Conference on the Principles of Knowledge Representation and Reasoning*, 2012.

Levy, O. and Goldberg, Y. Neural word embedding as implicit matrix factorization. In *Advances in neural information processing systems*, pp. 2177–2185, 2014.

Liu, P. J., Saleh, M., Pot, E., Goodrich, B., Sepassi, R., Kaiser, L., and Shazeer, N. Generating wikipedia by summarizing long sequences. *arXiv preprint arXiv:1801.10198*, 2018.

McCann, B., Bradbury, J., Xiong, C., and Socher, R. Learned in translation: Contextualized word vectors. In *Advances in Neural Information Processing Systems*, pp. 6294–6305, 2017.

McCann, B., Keskar, N. S., Xiong, C., and Socher, R. The natural language decathlon: Multitask learning as question answering. *arXiv preprint arXiv:1806.08730*, 2018.

Merity, S., Xiong, C., Bradbury, J., and Socher, R. Pointer sentinel mixture models. *arXiv preprint arXiv:1609.07843*, 2016.

Mikolov, T., Sutskever, I., Chen, K., Corrado, G. S., and Dean, J. Distributed representations of words and phrases and their compositionality. In *Advances in neural information processing systems*, pp. 3111–3119, 2013.

Nallapati, R., Zhou, B., Gulcehre, C., Xiang, B., et al. Abstractive text summarization using sequence-to-sequence rnns and beyond. *arXiv preprint arXiv:1602.06023*, 2016.

Paperno, D., Kruszewski, G., Lazaridou, A., Pham, Q. N., Bernardi, R., Pezzelle, S., Baroni, M., Boleda, G., and Fernández, R. The lambada dataset: Word prediction requiring a broad discourse context. *arXiv preprint arXiv:1606.06031*, 2016.

Pennington, J., Socher, R., and Manning, C. Glove: Global vectors for word representation. In *Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP)*, pp. 1532–1543, 2014.

Peters, M. E. and Lecocq, D. Content extraction using diverse feature sets. In *Proceedings of the 22nd International Conference on World Wide Web*, pp. 89–90. ACM, 2013.

Peters, M. E., Neumann, M., Iyyer, M., Gardner, M., Clark, C., Lee, K., and Zettlemoyer, L. Deep contextualized word representations. *arXiv preprint arXiv:1802.05365*, 2018.

Radford, A., Jozefowicz, R., and Sutskever, I. Learning to generate reviews and discovering sentiment. *arXiv preprint arXiv:1704.01444*, 2017.

Radford, A., Narasimhan, K., Salimans, T., and Sutskever, I. Improving language understanding by generative pre-training. 2018.

Ramachandran, P., Liu, P. J., and Le, Q. V. Unsupervised pretraining for sequence to sequence learning. *arXiv preprint arXiv:1611.02683*, 2016.

Recht, B., Roelofs, R., Schmidt, L., and Shankar, V. Do cifar-10 classifiers generalize to cifar-10? *arXiv preprint arXiv:1806.00451*, 2018.

Reddy, S., Chen, D., and Manning, C. D. Coqa: A conversational question answering challenge. *arXiv preprint arXiv:1808.07042*, 2018.

Schwartz, R., Sap, M., Konstas, I., Zilles, L., Choi, Y., and Smith, N. A. Story cloze task: Uw nlp system. In *Proceedings of the 2nd Workshop on Linking Models of Lexical, Sentential and Discourse-level Semantics*, pp. 52–55, 2017.

See, A., Liu, P. J., and Manning, C. D. Get to the point: Summarization with pointer-generator networks. *arXiv preprint arXiv:1704.04368*, 2017.

Sennrich, R., Haddow, B., and Birch, A. Neural machine translation of rare words with subword units. *arXiv preprint arXiv:1508.07909*, 2015.

Subramanian, S., Trischler, A., Bengio, Y., and Pal, C. J. Learning general purpose distributed sentence representations via large scale multi-task learning. *arXiv preprint arXiv:1804.00079*, 2018.

Sutskever, I., Vinyals, O., and Le, Q. V. Sequence to sequence learning with neural networks. In *Advances in neural information processing systems*, pp. 3104–3112, 2014.

Sutskever, I., Jozefowicz, R., Gregor, K., Rezende, D., Lillicrap, T., and Vinyals, O. Towards principled unsupervised learning. *arXiv preprint arXiv:1511.06440*, 2015.

Trichelair, P., Emami, A., Cheung, J. C. K., Trischler, A., Suleman, K., and Diaz, F. On the evaluation of common-sense reasoning in natural language understanding. *arXiv preprint arXiv:1811.01778*, 2018.

Trinh, T. H. and Le, Q. V. A simple method for commonsense reasoning. *arXiv preprint arXiv:1806.02847*, 2018.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., and Polosukhin, I. Attention is all you need. In *Advances in Neural Information Processing Systems*, pp. 5998–6008, 2017.

Vinyals, O. and Le, Q. A neural conversational model. *arXiv preprint arXiv:1506.05869*, 2015.

Vinyals, O., Fortunato, M., and Jaitly, N. Pointer networks. In *Advances in Neural Information Processing Systems*, pp. 2692–2700, 2015.

Wang, A., Singh, A., Michael, J., Hill, F., Levy, O., and Bowman, S. R. Glue: A multi-task benchmark and analysis platform for natural language understanding. *arXiv preprint arXiv:1804.07461*, 2018.

Weston, J. E. Dialog-based language learning. In *Advances in Neural Information Processing Systems*, pp. 829–837, 2016.

Wieting, J. and Kiela, D. No training required: Exploring random encoders for sentence classification. *arXiv preprint arXiv:1901.10444*, 2019.

Wolf, T., Sanh, V., Chaumond, J., and Delangue, C. Transfertransfo: A transfer learning approach for neural network based conversational agents. *arXiv preprint arXiv:1901.08149*, 2019.

Yogatama, D., d'Autume, C. d. M., Connor, J., Kocisky, T., Chrzanowski, M., Kong, L., Lazaridou, A., Ling, W., Yu, L., Dyer, C., et al. Learning and evaluating general linguistic intelligence. *arXiv preprint arXiv:1901.11373*, 2019.

8. 附录 A：生成样本 (Appendix A: Samples)

8.1. 模型容量 (Model capacity)

为了补充图 4 中展示的更大语言模型在 WebText 上的困惑度提升，表 7 至表 11 并排展示了最小的 WebText 语言模型与 GPT-2 在随机未见过的 WebText 测试集文章上的续写结果。

8.2. 文本记忆 (Text Memorization)

我们在 GPT-2 中观察到对数据集中多次重复的较长字符串（如著名名言或演讲）存在一定的记忆行为。例如，当以《葛底斯堡演说》（Gettysburg Address，在整个 WebText 中大约出现了 40 次）的前一句半作为条件时，对 GPT-2 进行 argmax（贪心）解码能够恢复整篇演说。即便在不截断的情况下进行采样，我们也发现模型会先复制演说一段时间，然后才发生偏离（drift），不过偏离后仍保持相似的风格。它通常在 100–200 个词元内发生偏离，并在偏离后展现出不断扩大的多样性。

为了量化精确记忆在样本中出现的频率，我们以 WebText 测试集文章为条件从 GPT-2 生成样本，并将 GPT-2 生成内容的重叠率与真实（ground-truth）续写内容的重叠率进行了比较。该分析的结果如下所示，表明 GPT-2 重复训练集文本的频率低于保留集文章的基线重叠率。

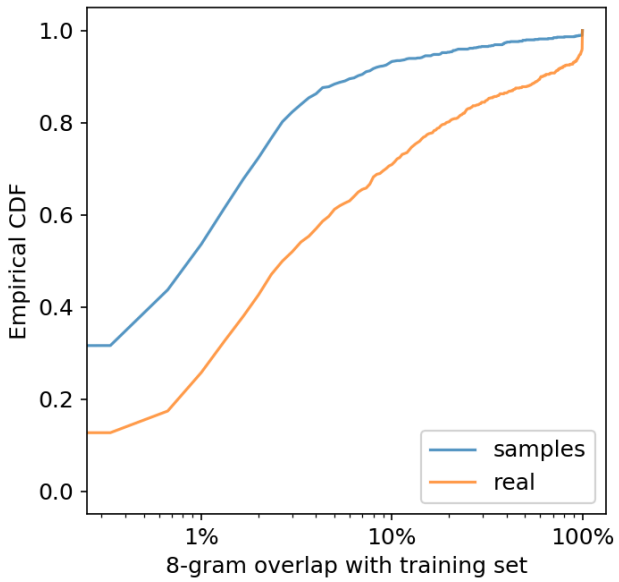


图 ***5 (Figure 5).*** WebText 测试集以及生成样本（以 WebText 测试集为条件，使用 $k = 40$ 的 top-k 截断随机采样）与 WebText 训练集之间 8-gram 重叠百分比的经验累积分布函数（CDF）。大多数样本的重叠率低于 1%，其中超过 30% 的样本没有任何重叠，而测试集的中位数重叠率为 2.6%。

8.3. 多样性 (Diversity)

表 12 展示了对同一个随机 WebText 测试集上下文的多次续写结果，展现了在标准采样设置下生成续写的多样性。

8.4. 鲁棒性 (Robustness)

表 13 展示了前文提到的“会说话的独角兽”新闻文章。我们发现模型有能力处理偏离分布（out-of-distribution）的上下文，但这类样本的质量通常较低。

<table>
<tr><th colspan="2">上下文（WebText 测试集） / Context (WebText test)</th></tr>
<tr><td colspan="2">穿搭 1：日常典型风（Outfit 1: Typical）

这套搭配是我买下这双鞋时想到的第一套穿搭。它就像是 Jake Grantham 那套穿搭的夏季版；事实上，我这双鞋的配色和他的 Nike Racers 非常接近！我没有穿厚重的哈里斯粗花呢（Harris Tweed）夹克和牛仔衬衫，而是穿了一件棉质双排扣（DB）夹克和一件亚麻衬衫。这两种面料（以及这些颜色）绝对是夏季必备，因为它们既能配深色裤子也能配浅色裤子！如你所见，它们与深色牛仔裤和鞋子搭配得极为出色。这是一套偏男装/学院风（pseudo menswear/prep）的穿搭。

总的来说，这是一套非常休闲的穿搭，这也是我用运动鞋来搭配它的原因。我并不赞成穿全套羊毛西装配运动鞋（就像《GQ》经常展示的那样），但我绝对乐意保持休闲感，比如这件棉质双排扣夹克。休闲面料是在偏日常的男装穿搭中驾驭运动鞋的关键。我甚至建议用这双运动鞋搭配卡其布斜纹棉西装或白色亚麻西装。只是务必拿掉领带，或者内搭 T 恤或 Polo 衫；穿运动鞋还系领带就有点过了——</td></tr>
<tr><th>小型模型续写 (Small model completion)</th><th>GPT-2 续写 (GPT-2 completion)</th></tr>
<tr><td>。

穿搭 2：高端风（Outfit 2: High End）

这套穿搭正处于风暴中心。它是 ASICS 在街头服饰（比如 J. Crew）上的做法与 J. Crew 在略带传统感的休闲单品上的做法的混合体。再说一次，正如我之前提到的，这是一件低预算单品，而且它们可能会非常昂贵。如果你想作为一名休闲运动鞋制造者来工作，这些肯定会是个问题，这没关系，但如果你想尝试他们平价版本的穿搭，千万不要犹豫！

这个版本采用了非常低领口的剪裁（这并不是件坏事）、稍微长一点的裤腿，以及一双修长的腿来保持整体的美观。这些单品我首选的颜色是蓝灰色（这是我的第一选择颜色，因为它们是浅白色的），或者是黑色（这是我设计中最喜欢的颜色）。一如既往，我从这家店挑选的颜色除了设计本身外别无他求。对于高端风格来说，我向所有人推荐这套！

穿搭 3：高光风（Outfit 3: High Light）

这是我有机会去晒出点肤色时的一套“高光”造型。我认为这个颜色是基于</td><td>（对我来说）！

穿搭 2：休闲夹克（Outfit 2: Casual Jacket）

我知道有些人可能反对穿高领毛衣配运动鞋，但我想忠于自己的风格，所以我选了一件修身的高领毛衣，颜色更接近我当天最喜欢的颜色。总体而言，这是一件经典的高领毛衣，没有什么过于花哨的地方。我确实把鞋子换成了这双 ASICS Tiger Killshots，真希望我没这么干。鞋子本身非常舒适，然而我发现穿这双运动鞋会让我的脚看起来大了一点。我会用它们搭配牛仔裤、斜纹棉布裤之类的，但绝不建议单独（光腿）穿它们。这里面涉及的变量实在太多了。

穿搭 3：正装风（Outfit 3: Dress）

这是我穿 ASICS Tiger Killshots 搭配的最后一套造型。这个版本的 ASICS 是更加现代、流线型的版本。这双鞋拥有我能想到的最现代、最极简的设计！大量的黑色点缀让这双运动鞋看起来非常酷。它们在夏天穿起来肯定会非常舒服。

对我来说，用西装来搭配它们是拥有一双好运动鞋最简单的方式。差不多就是这样！如果</td></tr>
</table>

表 ***7 (Table 7).*** 随机未见过的上下文（顶部），以及来自最小模型（左）和最大模型（右）未经挑选（non-cherry-picked）的续写结果。上下文长度为 768 个词元，表中展示了大约 256 个词元的段落。续写长度为 256 个词元且完整展示。生成时使用了 $k = 40$ 的 Top-k 随机采样。

<table>
<tr><th colspan="2">上下文（WebText 测试集） / Context (WebText test)</th></tr>
<tr><td colspan="2">西班牙一些最辉煌的历史名胜可以追溯到穆斯林统治时期，包括最初作为科尔多瓦大清真寺（Great Mosque of Córdoba）建造的梅斯基塔（The Mezquita），以及同样位于科尔多瓦、如今虽已成废墟但仍可参观的扎赫拉古城（Medina Azahara，作为安达卢斯宫殿 Madinat al-Zahra 建造）；还有位于格拉纳达、富丽堂皇且保存完好的阿尔罕布拉宫（Alhambra）。此外，还有两座建于穆斯林西班牙时期的犹太会堂屹立至今：托莱多的圣玛丽亚拉布兰卡犹太会堂（Santa María la Blanca）以及位于老城区的科尔多瓦犹太会堂（Synagogue of Córdoba）。

收复失地运动与帝国时代 [编辑] (Reconquista and Imperial era [edit])</td></tr>
<tr><th>小型模型续写 (Small model completion)</th><th>GPT-2 续写 (GPT-2 completion)</th></tr>
<tr><td>穆斯林西班牙时代与世界其他地方截然不同，拥有相当广泛的中世纪历史。虽然西班牙帝国存在于公元前 9 世纪下半叶，但到公元 1150 年，它相当缓慢地转变成了一个小型的世俗化帝国，处于一个更加繁荣和多样化的状态。公元 1050 年，那不勒斯皇帝——至少部分特征是一系列从该地区西北海岸延伸到西海岸的战争和入侵（例如在多瑙河上，该河从直布罗陀一直延伸到西班牙南部，但在同一天被罗马军队迅速摧毁）——承袭了那不勒斯皇帝的头衔。他在过去几十年里做出了巨大贡献以恢复和维持该帝国，其中第一个向西扩展。他的继任者是斐迪南（Ferdinand），于 1148 年从教皇宝座手中夺取了权力，而第一位帝国继任者是瑞典国王阿尔弗雷德二世（King Alfred II of Sweden）。该帝国再次成为欧洲大陆为数不多的独立国家之一，尽管在这一时期生活在其领土上的人口不超过 2 亿，但人们对皇帝有很多话要说。从 1720 年起，穆斯林占了西班牙人口的一半。</td><td>1092 年和 1095 年的收复失地运动（Reconquista，字面意思为“重返故土”）见证了伊比利亚半岛上卡斯蒂利亚和阿拉贡联合王国的建立，其中仍存在一个穆斯林王朝。这是欧洲历史上最后一次将穆斯林统治视为“本土”统治，也是基督教激发的有组织冲突最后一次在欧洲显露声威。

穆斯林摩尔人在西班牙的统治（尤其是在非穆斯林群体中）通常被称为“格拉纳达征服（Conquest of Granada）”，而西班牙有时也被称为“格拉纳达”的西班牙。穆斯林统治的最后岁月随后迎来了西班牙收复失地运动，随着 1189 年 3 月斐迪南九世（Ferdinand IX）在普瓦捷战役（Battle of Poitiers）中的胜利以及 1187 年萨拉丁（Saladin）征服耶路撒冷，穆斯林被驱逐或被迫离开伊比利亚半岛。

当摩尔人向北撤退时，西班牙的收复失地运动时期宣告结束。然而，摩尔人的统治并未被基督教统治完全取代，直到收复失地运动时代重新开始，并从 1229 年一直持续到 1492 年。

西班牙最后一个穆斯林政权格拉纳达（Granada）被征服于</td></tr>
</table>

表 ***8 (Table 8).*** 随机未见过的上下文（顶部），以及来自最小模型（左）和最大模型（右）未经挑选的续写结果。上下文长度为 768 个词元，表中展示了大约 256 个词元的段落。续写长度为 256 个词元且完整展示。生成时使用了 $k = 40$ 的 Top-k 随机采样。

上下文（**WebText** 测试集） **/ Context (WebText test)**	
Pinky（粉红幽灵） 粉红幽灵的 AI 被设计为在“感觉”上与红色幽灵的行为正好相反。Pinky 实际上试图绕到吃豆人（Pac-Man）的前面。这是通过将目标设定在吃豆人当前位置沿其移动方向往前 4 格（tiles）来实现的。唯一的一个例外是当吃豆人向上移动时：由于代码中的一个溢出错误（overflow bug），计算结果会额外包含一个等于预期向上偏移量的向左偏移量。 对吃豆人预期位置的使用，使得玩家可以利用 Pinky 的导航代码。这种情况最常见于吃豆人和 Pinky 彼此距离很近的时候。例如，如果他们正对着彼此移动，一旦两者相距小于 4 格，目标格就会落到 Pinky 的身后。如果他在这种状态下遇到十字路口，他会尝试折返（通过转身）以到达目标格。 当 Pinky 接近十字路口时，玩家经常会通过快速改变方向来做出被称为“假动作（head fake）”的操作。通过就在 Pinky	
小型模型续写 **(Small model completion)**	**GPT-2** 续写 **(GPT-2 completion)**
向左边走来的时候移动目标格，他们就能获得“正确的”方向。 如果该位置实际上离吃豆人所在的位置更远，玩家的移动不会对幽灵的移动产生响应，幽灵反而会返回到玩家的当前位置。这是因为吃豆人并不是通过转动来移动的。 幽灵将不得不前往某种其他位置以回到他出发的地方，而这可以通过多种方式实现。它往往会直接离开该位置，例如如果吃豆人跳下悬崖，他会回到消失在太空中之前所在的位置。这些幽灵路径可能存在很多种可能性，但最明显的情况是当玩家想要避免在游戏中被抓住时，其目标很简单，就是让吃豆人在游戏里多撑 1/3 的时间。 追逐（Chasing） 在吃豆人的例子中，这类似于吃豆人如何在战斗中“追赶”。 幽灵可以穿过敌人进行追逐。这由于许多原因而非常有用，无论对吃豆人还是对他的 AI 都是如此。与大多数幽灵游戏不同，这个幽灵只是沿着来自	即将穿过十字路口时移动目标格，吃豆人就能够躲避幽灵的投射物并返回安全屋（safe house）的安全位置。 Buster 黄色幽灵的 AI 是专门设计用来阻止吃豆人离开安全屋的。玩家必须按下空格键（SPACE）才能显现出安全屋的门，然后走进去在隔壁房间找到躲藏的黄色幽灵。 玩家还必须注意，如果幽灵看到吃豆人已经在安全屋里，它是不会尝试离开安全屋的。事实上，除非他们已经在安全屋里，否则幽灵根本不会尝试离开。 这两种行为是基于这样一个事实：玩家并不总是试图在吃豆人（或 Blinky）之前到达安全屋。 如果幽灵（或另一名玩家）已经在安全屋中，并且试图在吃豆人或 Blinky 离开后立即出去，玩家还必须小心这个漏洞（glitch）。在这一点上，幽灵会尝试以与“追逐（Chase）”模式下相似的方式离开安全屋。 吃豆人（Pac-Man） 有一些幽灵会跟随吃豆人。这些幽灵是

表 ***9 (Table 9).*** 随机未见过的上下文（顶部），以及来自最小模型（左）和最大模型（右）未经挑选的续写结果。上下文长度为 768 个词元，表中展示了大约 256 个词元的段落。续写长度为 256 个词元且完整展示。生成时使用了 $k = 40$ 的 Top-k 随机采样。

上下文（**WebText** 测试集） **/ Context (WebText test)**
下士迈克尔·P·戈尔丁（Corporal Michael P. Goeldin）在 1860 年 11 月入伍加入 A 连时，是一名来自爱尔兰的非熟练劳工。戈尔丁在战争中幸存了下来。同样来自爱尔兰的下士帕特里克·奥尼尔（Corporal Patrick O'Neal）于 1854 年首次入伍，在俄勒冈州的美国第三炮兵团 L 连服役。他后来返回东海岸，并于 1860 年入伍加入该连。奥尼尔一直服役到 1874 年，之后被任命为纽约州威利茨角（Willets Point）国家公墓的主管。下士本杰明·布朗（Corporal Benjamin Browne）是来自纽约州奥兰治县的一名鞋匠。1862 年 8 月，他入伍加入新组建的纽约第 124 志愿步兵团，并成为当年 10 月转入 A 连的 61 名士兵之一。1864 年 2 月，当部队在布兰迪车站（Brandy Station）扎营时，布朗重新入伍留在该连。他在 1867 年服役期满后回归平民生活。 6 月 10 日，技工威廉·柯林斯（Artificer William Collins）被晋升为下士，可能是为了填补渡过詹姆斯河（James River）作战时的基层指挥空缺。柯林斯的服役记录并未体现出他为赢得这次晋升所展现出的品质，但他显然已经克服了一些严重的问题。柯林斯出生于纽约州萨基茨港（Sacketts Harbor），于 1853 年 12 月年满 22 岁时入伍加入该连，并于 1858 年 12 月重新入伍。就在 1861 年 4 月战争爆发前一个月，柯林斯"翻山越岭当了逃兵（went over the hill）"，直到三年后才被抓获。1864 年 3 月 22 日被押回连队后，他接受了审判——

小型模型续写 **(Small model completion)**	**GPT-2** 续写 **(GPT-2 completion)**
因军事指控受审，并被美国陆军开除军籍。他回到了连队，并在内战期间被分配到内部事务司（Division of Internal Affairs）。 作为一名工程师，柯林斯还在他的家乡纽约接受过工程培训。在联合工程学院（Union College of Engineering）完成研究生学业后，他同时受雇于美国陆军两年。在那里，他在丹尼尔·普发伊弗上尉（Captain Daniel Pfeiffer）手下工作，并在普发伊弗上尉入伍三年后的 1870 年 5 月晋升为上校。柯林斯在第一师完成第一年服役后返回英国老家，随后在陆军工程兵团服役了接下来的两年，到第二年时，他开始经历他的服役职责。<|endoftext|>莫斯科，7 月 5 日（路透社）——总部位于英国的俄罗斯国家媒体以及政府消息人士和专家表示，莫斯科一直在设法淡化叙利亚反对派的"军事集结"，同时维持对唐纳德·特朗普总统在美墨边境修建隔离墙计划的支持，称其为一场"军事政变"。 美军领导的叙利亚战争老兵兼叙利亚特使迈克尔·弗林（Michael Flynn，右）与驻美国的叙利亚政治分析家艾哈迈德·科里亚特（Ahmet Koryat）一起做手势，随行的还有	于同年 6 月受审。他因开小差被判处枪决，但仍留在现役部队中。 詹姆斯·J·达尔上尉（Captain James J. Dall）于 1829 年革命期间出生在弗吉尼亚州，并于 1836 年追随父亲加入陆军。他在弗吉尼亚第二步兵团服役至 1845 年，随后转入西部预备役团（Western Reserve Regiment）；退伍后，他又重新入伍加入纽约第 25 志愿步兵团 I 连（1845 年时该团约有 4,500 人）。他的一个兄弟詹姆斯（James）也在同一个旅的同一个连队以相同身份服役。当该团在 1846 年一直驻扎在康涅狄格州期间，达尔上尉在退伍前的不同时期曾在 I 连服役。作为美墨战争的老兵，他曾在圣安东尼奥的约翰·J·沙利文准将（Brigadier General John J. Sullivan）参谋部服役两年。在 1863 年的半岛战役（Peninsula Campaign）期间，他指挥一个由 23 人组成的连队，并负责管理由 54 门重型迫击炮组成的炮兵连以及该炮兵连的"平塔号（Pinta）"炮艇和另外几艘船只。1865 年秋，达尔上尉在 I 连服现役。两年后，他被晋升为少尉。 约翰·A·奥（Captain John A. O'）上尉

表 ***10 (Table 10).*** 随机未见过的上下文（顶部），以及来自最小模型（左）和最大模型（右）未经挑选的续写结果。上下文长度为 768 个词元，表中展示了大约 256 个词元的段落。续写长度为 256 个词元且完整展示。生成时使用了 $k = 40$ 的 Top-k 随机采样。

上下文（**WebText** 测试集） **/ Context (WebText test)**	
Xmonad、Xresources 与字体（Xmonad, Xresources, and Fonts） Xresources 可能会让人无比头疼（对我来说就是这样）。所以，这里提供一点帮助： 首先，Xmonad 中处理字体的方式通常是通过 XFT。Xft 是 X FreeType 接口库，也是一个处理 Xmonad/urxvt 中实际字体渲染的库（Xresources 为在 X 窗口管理器下启动的程序指定了一系列资源。单个程序的设置在 Xresources 中按如下方式指定：`Urxvt.background:background settins here`）。 不管怎样，在 Xresources 中使用以下语法来设置字体： `urxvt*font:xft:your font name goes here:size=the size of the font goes here,xft:fall-back font 1 goes here` 以上就是通过 Xresources 指定 urxvt 字体的最基础部分。 修复 Cygwin 中的 `/.ssh/` 权限（Fixing /.ssh/ Permissions in Cygwin） 在 Windows 上的 Cygwin 中，我发现无法将我的 `/.ssh/` 文件夹权限设置为 `0600`，而这是 ssh 允许你使用密钥所必需的。我遇到的症状是，无论我做什么，它总是修改所有者和用户组——	
小型模型续写 **(Small model completion)**	**GPT-2** 续写 **(GPT-2 completion)**

被设置为 `/.ssh/`，原本就是这样的。这个问题无法彻底修复。我发现只要用鼠标输入用户名，然后尝试将用户组的权限设置为“0600”，就能让它好用得多，这也是我现在系统的配置方式。
 	
然而，从 Linux 上的 Cygwin 7 开始，我发现对我的系统来说这样做现在是“不必要的”！我还安装了一个名为 `chroot` 的软件包。它通过允许你安装/升级到系统目录来实现这一点。
 	
因此，从 Windows 8 及更高版本开始，安装它可能需要 `chroot`，所以我试了又试，发现在 Linux 上安装该软件包然后再卸载时并没有那么糟糕。正如我上一篇关于 Cygwin 的文章所述，该脚本只是完成它的本职工作（其余的由 sudo 命令完成），如果你尝试的话，你将必须记录该更改。
 	
如果这还不够让人困惑的话，这就是我所尝试的方法，然后我直接回到了我的 `/.ssh/` 目录和 `chroot` 脚本。我发现我终于耗尽了权限（因为我忘记创建从文件系统到 ssh 的符号链接，并且
	，使得这些文件变成只读。我尝试过直接启动 ssh 并使用像 `passwd` 这样会将所有者/用户组修改为 `0644` 权限的程序，但没有奏效。这虽然让人心烦，但远没有可能发生的最坏情况那么糟，只是不得不折腾权限让人觉得烦人罢了。
	
	所以我决定反过来做：
	
	对于你 Cygwin 目录中的每一个 `.ssh` 文件夹，将每个文件和目录的权限设置为 `2644`。然后使用以下命令启动 ssh：`ssh-add /.ssh/`
	
	当你第一次连接时，你刚才在 Cygwin 中拥有的 `/.ssh` 文件夹权限将被设置为 `0600`。然后每次你再次连接时，你的权限都会变成 `0644`。
	
	在 `/.xsessionrc` 中使用的 Xresources 的 Makefile
	
	这些是在我的 `.xsessionrc` 中创建的：
	
	`.xprofile: .xsession-errors: color=""`
	
	例如：
	
	`.xprofile: color=blue`
	
	由于颜色存储在单独的文件中，你的 `/.xsession-errors` 中的颜色看起来会是青色（cyan）而不是蓝色（blue）。
	
	这主要是因为，截至目前，只有颜色被分配给了你的

表 ***11 (Table 11).*** 随机未见过的上下文（顶部），以及来自最小模型（左）和最大模型（右）未经挑选的续写结果。上下文长度为 768 个词元，表中展示了大约 256 个词元的段落。续写长度为 256 个词元且完整展示。生成时使用了 $k = 40$ 的 Top-k 随机采样。

上下文（**WebText** 测试集） **/ Context (WebText test)**		
Aaron 非常喜欢薄荷巧克力蛋糕，但他要求必须搭配迷你巧克力豆，所以我在蛋糕夹层之间撒了一些。我手头刚好还有几块薄荷夹心饼干（Peppermint Jo Jos），于是我把它们捏碎，连同一些捏碎的蛋白霜饼干（meringue cookies）一起撒了进去，因为——为什么不呢？这简直就是一场薄荷巧克力豆饼干酥脆美味的盛宴（smorgasbord）。我没有称量每种配料具体放了多少，但在品尝了成品之后，我真希望自己当时再多放一点。你可以添加任何你想要的东西——碾碎的拐杖糖、薄荷巧克力脆片等等。而且下手重一点也完全不用怕。口感 = 绝佳。 如果你没有 7 英寸的蛋糕烤盘，你可以用这个——		
GPT-2 续写 **1 (Completion 1)**	**GPT-2** 续写 **2 (Completion 2)**	**GPT-2** 续写 **3 (Completion 3)**
食谱做出 3 个矮一点的 8 英寸蛋糕层。我做了加长版，然后用烤盘做了一层奶油霜（buttercream frosting），并把其中的 1/3 放进冰箱作为顶层糖霜。只要确保你在制作这个蛋糕之前提前准备好所有这些糖霜，这样当蛋白留在搅拌碗底部时，你就不必干等着它了。 你想把蛋白打发到硬性发泡（stiff peaks）吗？那就把你的蛋糕盘放在一锅微沸的水上加热，直到它刚刚温热。这不需要超过 3–5 分钟；刚好够让它开始	食谱做出 3 个矮一点的 8 英寸蛋糕层。如果你这么做了，而且你知道怎么做那个蛋糕，那么你的生活将从此彻底改变。 说到饼干碎或巧克力豆，我有两条非常简单的原则。1) 当我购买原糖（raw sugar）时，在它冷却下来并且上面至少有半茶匙糖之前，我是不会使用它的。这是我的原则。2) 如果我有一个需要某种食材的食谱，并且我想在食谱中使用它，我绝不会用网上的其他东西来替代它。就像这样。 我发现了这张印着可爱小猫咪的超级可爱的卡片	食谱做出 3 个矮一点的 8 英寸蛋糕层，做出来的蛋糕分量大概也是一样的。 巧克力酪乳蛋糕（Chocolate Buttermilk Cake） 打印 大块的巧克力蛋糕，裹上酪乳，顶部铺满酥脆的切碎巧克力，再淋上巧克力酱。虽然简单，但相比普通巧克力蛋糕是个很棒的变化！作者：Momma Made 食材（巧克力酪乳蛋糕部分）： 1 又 1/2 杯无盐黄油，室温软化 1 又 1/2 杯细砂糖 3 个大号鸡蛋加 1 个蛋黄 巧克力淋面（chocolate glaze）部分： 1/3 杯可可粉 1 又 3/4 杯糖粉 6 盎司半甜（semis）
GPT-2 续写 **4 (Completion 4)**	**GPT-2** 续写 **5 (Completion 5)**	**GPT-2** 续写 **6 (Completion 6)**
食谱做出 3 个矮一点的 8 英寸蛋糕层。 蛋白霜饼干（Meringue Cookies） 1 又 3/4 杯黄油，软化 1 杯糖 1 个蛋黄 3 大汤匙浓奶油 3 又 1/2 至 4 杯面粉 一撮盐 薄荷 Jojo 顶料（Peppermint-Jojo Topping） 1 又 1/4 杯糖粉 1 杯切碎的碧根果（pecans） 1/2 杯切碎的薄荷叶 1/2 杯切碎的新鲜薄荷（约 1/2 张） 1 茶匙薄荷提取物 1/4 茶匙海盐 一撮海	食谱做出 3 个矮一点的 8 英寸蛋糕层。 我在圣诞节早晨的两次失败并不是因为抹糖霜的技术不好。那是另一个成功的故事了。这个蛋糕湿润得恰到好处，怎么说呢，就是一个漂亮的蛋糕。它内部几乎没有多余的气孔或水分，所有的巧克力和薄荷都完美地融合在了一起。 唯一让我有点抓狂的事情是，所有那些食材——蛋黄、糖、融化的黄油、巧克力豆、融化的巧克力和薄荷——都必须直接混合进蛋糕面糊里，这超级耗时。一位朋友建议说，如果我把面糊放在一个单独的碗里，我	食谱做出 3 个矮一点的 8 英寸蛋糕层，大约可以提供 6–9 人份的美味巧克力蛋糕。为了防止蛋糕层粘在一起，我用了我的 8 英寸圆形挞盘，铺上烘焙油纸（parchment paper），然后从中切出 4 个 7 英寸的圆形蛋糕胚，并将夹层夹在它们中间（这种方法对单层巧克力蛋糕也同样适用）。当你准备好烘烤这个蛋糕时，撕掉烘焙油纸，将烤箱预热到 350 华氏度，烘烤约 30–40 分钟，直到顶部呈金黄色且插入测试牙签拔出时干净无粘连。 薄荷 Jo 巧克力酪乳千层蛋糕（Chocolate Buttermilk Layer Cake with Peppermint Jo）

表 ***12 (Table 12).*** GPT-2 从同一上下文（来自 WebText 测试集）生成的未经挑选的续写结果。上下文长度为 384 个词元（展示时有截断），生成长度为 128 个词元。生成时使用了 $k = 40$ 的 Top-k 随机采样。

上下文（人类撰写）/ **Context (human-written)**：在一项令人震惊的发现中，科学家在安第斯山脉一个偏远、此前从未被探索过的山谷中发现了一群生活在那里的独角兽。更令研究人员惊讶的是，这些独角兽能说一口流利的英语。 (In a shocking finding, scientist discovered a herd of unicorns living in a remote, previously unexplored valley, in the Andes Mountains. Even more surprising to the researchers was the fact that the unicorns spoke perfect English.)
GPT-2：科学家根据它们独特的角，将这一种群命名为“奥维德独角兽（Ovid's Unicorn）”。这些长着四只角、银白色的独角兽此前在科学界鲜为人知。 如今，在将近两个世纪之后，究竟是什么引发了这一奇特现象的谜团终于被解开了。 来自拉巴斯大学（University of La Paz）的进化生物学家豪尔赫·佩雷斯博士（Dr. Jorge Pérez）和几名同伴当时正在安第斯山脉进行考察，他们发现了一个小山谷，里面没有其他动物或人类。佩雷斯注意到，山谷里有一处看似天然喷泉的地方，四周环绕着两座岩石与银雪交织的山峰。 佩雷斯和其他人随后进一步深入山谷。“当我们到达一座山峰的顶端时，水看起来是蓝色的，上面还有一些结晶体，”佩雷斯说道。 佩雷斯和他的朋友们看到这群独角兽时大吃一惊。从空中无需移动太多就能看到这些生物——它们离得如此之近，以至于研究人员几乎能摸到它们的角。 在观察这些奇异的生物时，科学家们发现这些生物还会说一些相当标准的英语。佩雷斯表示：“例如，我们可以看到它们拥有一种共同的‘语言’，某种类似于方言或语系（dialectic）的东西。” 佩雷斯博士认为，这些独角兽可能起源于阿根廷，人们认为那里的这些动物是在人类抵达南美洲那些地区之前生活在当地的失落民族的后裔。 虽然它们的起源尚不清楚，但有些人认为，这些生物或许是在人类文明之前的某个时代，由一名人类和一只独角兽相遇而创造出来的。据佩雷斯所说，“在南美洲，这类事件似乎相当普遍。” 不过，佩雷斯也指出，想要确切知晓独角兽是否真的是失落外星种族的后裔，唯一的方法可能是通过 DNA 检测。“但它们似乎能够用英语进行相当良好的交流，我认为这是进化的标志，或者至少是社会组织发生变化的一种体现，”这位科学家说道。

表 ***13 (Table 13).*** GPT-2 在偏离分布（out-of-distribution）的上下文上的条件生成结果。从使用 $k = 40$ 生成的 10 个样本中精选（cherry pick）所得。

<table>
<tr><td colspan="2">文章 (Article)：36,000 年前，史前人类在如今法国境内的一个洞穴粗糙的石灰岩壁上，绘制了数量惊人的史前野兽画作。
如今，在尖端技术的帮助下，肖维-蓬达尔克洞穴（Chauvet-Pont-d’Arc Cave）中的这些艺术作品得以复刻，造就了世界上最大的复制洞穴。这座名为蓬达尔克洞穴（Caverne du Pont-d’Arc）的人造洞穴建在距离法国南部瓦隆蓬达尔克（Vallon-Pont-D’arc）原址几英里远的地方，包含了 1,000 幅精心复刻的壁画以及约 450 块兽骨和其他特征……
36,000 年前，穴居男女在一个洞穴粗糙的石灰岩壁上绘制了数量惊人的史前野兽，而如今一个复制洞穴已经建成（如图所示）
……</td></tr>
<tr><td>GPT-2：位于法国南部瓦隆蓬达尔克的原址是一处联合国教科文组织世界遗产，也是已知最古老且保存最完好的人类装饰洞穴。复制洞穴建在距离法国南部瓦隆蓬达尔克原址几英里远的地方。该洞穴包含 14 种不同动物的图像，包括披毛犀、猛犸象和大型猫科动物。</td><td>参考摘要 (Reference)：该洞穴模仿了法国著名的蓬达尔克洞穴——最古老且保存最完好的人类装饰洞穴。复制洞穴包含了全部 1,000 幅壁画，其中包括披毛犀和猛犸象等 425 幅动物画作。微小的细节均使用 3D 建模和变形（anamorphic）技术进行了复制，这些技术通常用于拍摄宽银幕图像。这座现代洞穴还包括保存在原洞穴中的熊掌印、兽骨和细节的复制品。</td></tr>
<tr><td colspan="2">文章 (Article)：“如果你能找到我的潜艇，它就归你了，”俄罗斯石油亿万富翁罗曼·阿布拉莫维奇（Roman Abramovich）曾这样说道。
这位寡头兼切尔西足球俱乐部老板的潜艇只是其价值 3 亿英镑的超级游艇“日蚀号（Eclipse）”（非常适合神不知鬼不觉地登岸）附带的额外装备之一，而他似乎并不是唯一一个一掷千金进行水下探险的富商。
海洋被称为地球上真正的“最后疆域”，至今仍极少被探索，以至于亿万富翁们正排队购买能够让他们一睹壮丽海景和世界海洋奇妙野生动物的水下潜航器。
因此，如果你银行账户里有几百万闲钱，并且想要拍出能真正秒杀所有人的度假快照和 Instagram 帖子，你可能会想抢购一台这样的装备……
畅享时光：OrcaSub 潜艇可在两个加压有机玻璃（Perspex）观景穹顶舱内带你潜入水下 2000 英尺，以获得最佳探险体验
……</td></tr>
<tr><td>GPT-2：U-Boat Worx 潜艇可以下潜至 984 英尺（300 米），并且能够潜入海底。它可用于潜水、浮潜甚至呼吸管潜水。该潜艇还配备了一个浮潜平台。</td><td>参考摘要 (Reference)：乘坐最先进的深海潜航器，体验一把当詹姆斯·邦德（007）大反派的感觉。有些潜航器可以从游艇变身为潜艇，另一些则可分离出来进行快速探险。Oliver’s Travels 提供其潜艇上的“一英里深海（Mile Low）”套餐，配备私人厨师和管家，每晚费用为 175,000 英镑。</td></tr>
<tr><td colspan="2">文章 (Article)：阿米娜·阿里·卡西姆（Amina Ali Qassim）正抱着她最小的外孙女坐在腿上，用头巾擦去眼泪。
这个女婴只有几个月大，空袭开始的那天晚上，她拼命想捂住孩子的耳朵。她说，在也门比里姆岛（Birim）的一座乡村清真寺里，她彻夜未眠，一边听着婴儿啼哭，一边数着爆炸声。
不过情况本可能会更糟。当第一枚导弹落下时，他们本可能还待在自己的房子里。
“我们的邻居对着我丈夫大喊：‘你们必须离开，他们来了。’于是我们拔腿就跑。我们刚一离开房子，第一枚导弹就落在了房子旁边，紧接着第二枚直接命中了房子。它把一切都夷为了平地，”卡西姆告诉我们
……</td></tr>
<tr><td>GPT-2：也门正处于内战之中。沙特阿拉伯正领导联军的轰炸行动。它轰炸也门至今已有两个多月了。</td><td>参考摘要 (Reference)：阿米娜·阿里·卡西姆的一家在逃离也门之前曾在一座清真寺里寻求庇护。成千上万像他们一样的人正登上船只前往吉布提。为了击败胡塞武装，沙特阿拉伯一直在猛烈轰炸也门。</td></tr>
</table>

表 ***14 (Table 14).*** GPT-2 在 CNN and Daily Mail 数据集测试集上生成的摘要与参考摘要对比。

英语参考原文 **(English reference)** This re-release, titled The Next Day Extra, was presented in the form of three disks: the original album, unpublished studio sessions and remixes, plus a DVD containing the four clips that have already been unveiled. 【中译：这次重新发行的版本名为《The Next Day Extra》，以三张光盘的形式呈现：原版专辑、未公开发行的录音室曲目和混音版，外加一张包含已揭晓的四个视频片段的 DVD。】	**GPT-2** 法语译文 **(GPT-2 French translation)** Les nouvelles re-releases, tout en premier disc, nécessaire de l'album, un studio session et remixes, plus une DVD de l'écran de quelques clips qui ont été déjà échappés. 【中译（按 GPT-2 法语字面译）：这些新的重新发行版，全在第一张光盘里，专辑所必需的、一个录音室曲目和混音，外加一张包含几个已经流出片段画面的 DVD。】
法语参考原文 **(French reference)** Un homme expliquait que le fonctionnement de la hernia fonctionnelle qu'il avait reconnaît avant de faire, le fonctionnement de la hernia fonctionnelle que j'ai réussi, j'ai réussi. 【注：原论文表 15 此处排印误将下一行的 GPT-2 法语译文粘贴到了此处；其对应上一句的转换。】	**GPT-2** 英语译文 **(GPT-2 English translation)** This release, originally released on three discs: the original album, sessions studio inédites and remixes, a DVD containing the four clips that were released on the previous day. 【中译：这次发行版最初以三张光盘发行：原版专辑、未发表的录音室曲目（保留了法语词）和混音，以及一张包含前一天发布的四个片段的 DVD。】
英语参考原文 **(English reference)** One man explained that the free hernia surgery he'd received will allow him to work again. 【中译：一名男子解释说，他接受的免费疝气手术将使他能够重新工作。】	**GPT-2** 法语译文 **(GPT-2 French translation)** Un homme expliquait que le fonctionnement de la hernia fonctionnelle qu'il avait reconnaît avant de faire, le fonctionnement de la hernia fonctionnelle que j'ai réussi, j'ai réussi. 【中译（按 GPT-2 法语字面译）：一名男子解释说，他在做之前所承认的功能性疝气的运作，我成功做到的功能性疝气的运作，我成功了。】
法语参考原文 **(French reference)** Un homme a expliqué que l'opération gratuite qu'il avait subie pour soigner une hernie lui permettrait de travailler à nouveau. 【中译：一名男子解释说，他为治疗疝气而接受的免费手术将使他能够再次工作。】	**GPT-2** 英语译文 **(GPT-2 English translation)** A man told me that the operation gratuity he had been promised would not allow him to travel. 【中译：一名男子告诉我，曾向他承诺的手术津贴（将法语 *gratuite*［免费］误译为 *gratuity*［小费/津贴］，*travailler*［工作］误译为 *travel*［旅行］）不足以让他去旅行。】
英语参考原文 **(English reference)** Speaking to an open government conference in London via video link, Mr Kerry said: "There is no question that the President and I and others in government have actually learned of some things that had been happening on an automatic pilot because the ability has been there, going back to World War Two and to the very difficult years of the Cold War, and then, of course, 9/11." 【中译：克里先生通过视频连线在伦敦举行的开放政府会议上发表讲话时说："毫无疑问，总统、我以及政府中的其他人实际上已经了解到，有些事情一直在按'自动驾驶'模式运行，因为这种能力一直存在，这可以追溯到第二次世界大战、冷战时期非常艰难的岁月，当然还有 9·11 事件。"】	**GPT-2** 法语译文 **(GPT-2 French translation)** Le premier conference de l'édition internationale en ligne sur la vide, le ministre de l'Édition internationale a été vide, lui dit : "Il n'y a qu'une question que le président et moi et tous les autres personnes d'une administration qui a été évident par la fois, par la part de la guerre, par la part de la guer 【中译（按 GPT-2 法语字面译）：关于虚空的国际在线版本第一次会议，国际出版部长是空的，对他说："只有一个问题，总统和我和一个政府的所有其他人，每次都很明显，通过战争的一部分，通过战……】
法语参考原文 **(French reference)** S'exprimant lors d'une conférence intergouvernementale à Londres par liaison vidéo, M. Kerry a déclaré: "Il est indéniable que le Président, moi-même et d'autres membres du gouvernement avons pris connaissance de certaines choses en mode pilote automatique parce que nous en avions la possibilité, dès la Seconde guerre mondiale et jusqu'aux années difficiles de la Guerre froide, puis bien sûr le 11 septembre." 【中译：克里先生在伦敦举行的一次政府间会议上通过视频连线发表讲话时宣布："不可否认的是，总统、我本人以及政府的其他成员已经了解到某些以自动驾驶模式运行的事情，因为从第二次世界大战开始，一直到冷战的艰难岁月，再到后来的 9 月 11 日，我们都具备那样的能力。"】	**GPT-2** 英语译文 **(GPT-2 English translation)** In a conference between the United States and London, Secretary of State John Kerry said: "It is indeniable that the President, myself and others of the government have been aware of certain certain choices that have been made in the past in order to be able to do certain things in a more automated way." 【中译：在美国和伦敦之间的一次会议上，国务卿约翰·克里说："不可否认的是，总统、我本人以及政府中的其他人已经意识到过去做出的某些选择，以便能够以更加自动化的方式去做某些事情。"】

表 ***15 (Table 15).*** GPT-2 生成的英译法和法译英翻译结果。

上下文（文章段落与先前的问答对） **/ Context (passage and previous question/answer pairs)**

2008 年夏季奥运会火炬传递于 2008 年 3 月 24 日至 8 月 8 日在 2008 年夏季奥运会开幕前举行，主题为“同一个世界，同一个梦想”（“one world, one dream”）。传递计划于 2007 年 4 月 26 日在中国北京公布。此次火炬传递也被组织者称为“和谐之旅”（“Journey of Harmony”），历时 129 天，火炬传递里程达 137,000 公里（85,000 英里）——这是自 1936 年夏季奥运会前开启这一传统以来距离最长的一次奥运火炬传递。

3 月 24 日在奥运会发源地希腊奥林匹亚点燃圣火后，火炬传递至雅典的帕纳辛奈科体育场（Panathinaiko Stadium），随后前往北京，于 3 月 31 日抵达。从北京出发，火炬沿着一条横跨六大洲的路线传递。火炬造访了丝绸之路沿线的多座城市，象征着中国与世界其他地区之间的古老联系。此次传递还包括携圣火从中国一侧登顶位于尼泊尔和中国西藏边境的珠穆朗玛峰（Mount Everest），该侧路线为此项活动专门进行了封闭。

Q: What was the theme（主题是什么）
A: “one world, one dream”.（“同一个世界，同一个梦想”。）

Q: What was the length of the race?（传递的长度是多少？）
A: 137,000 km（137,000 公里）

Q: Was it larger than previous ones?（它比以往的规模更大吗？）
A: No（不是）

Q: Where did the race begin?（传递从哪里开始？）
A: Olympia, Greece（希腊奥林匹亚）

Q: Is there anything notable about that place?（那个地方有什么著名之处吗？）
A: birthplace of Olympic Games（奥运会的发源地）

Q: Where did they go after?（之后他们去了哪里？）
A: Athens（雅典）

Q: How many days was the race?（这一段传递了多少天？）
A: seven（7 天）

Q: Did they visit any notable landmarks?（他们造访了什么著名地标吗？）
A: Panathinaiko Stadium（帕纳辛奈科体育场）

Q: And did they climb any mountains?（他们攀登了什么山峰吗？）
A:

模型回答 **(Model answer)**：Everest（珠穆朗玛峰）
众包标注者回答 **(Turker answers)**：unknown, yes, Yes, yes（未知，是的，是的，是的）

表 ***16 (Table 16).*** 精选的 CoQA 问答续写示例。

上下文（文章段落与先前的问答对） **/ Context (passage and previous question/answer pairs)**

汤姆（Tom）无论去哪儿都跟着 54 岁的秘书凯瑟琳·格林（Catherine Green）。凯瑟琳上班时，他在她的办公室里走来走去，还陪她一起去购物。“大多数人似乎都不介意汤姆，”凯瑟琳说，她觉得汤姆棒极了。“他是我的第四个孩子，”她说。她或许真的把他当成自己的儿子来看待和照顾。他四处走动，由她给他买食物、付医疗账单并替他交税，但事实上汤姆是一只狗。

凯瑟琳和汤姆住在瑞典，在这个国家，每个人都被期望按照政府制定的规则过着井然有序的生活，政府也为国民提供高水平的福利保障。这种高水平的保障是需要花钱的。

瑞典人做什么都要交税，因此发现养狗意味着要交更多税也就不足为奇了。有些人为了拥有养狗的权利，每年要缴纳高达 500 瑞典克朗的税款，政府将这些钱用于建设宠物狗医院，有时也用于为生病的狗提供医疗救治。然而，大多数这类治疗都很昂贵，因此狗主人通常决定为他们的爱犬购买医疗保险甚至人寿保险。

在瑞典，狗主人必须赔偿他们的狗所造成的任何损失。瑞典养犬俱乐部（Swedish Kennel Club）的一名官员解释了这意味着什么：如果你的狗跑到马路上被路过的汽车撞了，作为主人，你必须赔偿汽车受到的任何损坏，哪怕你的狗在事故中被撞死了。

Q: How old is Catherine?（凯瑟琳多大年纪？）
A: 54

Q: where does she live?（她住在哪里？）
A:

模型回答 **(Model answer)**：Stockholm（斯德哥尔摩）
众包标注者回答 **(Turker answers)**：Sweden, Sweden, in Sweden, Sweden（瑞典，瑞典，在瑞典，瑞典）

表 ***17 (Table 17).*** 精选的 CoQA 问答续写示例。（注：模型未回答文中提到的“瑞典”，而是利用自身参数中的世界知识关联推断出了瑞典首都“斯德哥尔摩”。）